

Modelos Generativos Profundos

Clase 2: Repaso de probabilidad y redes neuronales

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

Probabilidades

Redes neuronales

Probabilidades

Variables aleatorias discretas

- Una **variable aleatoria** es una función $x : \Omega \rightarrow \mathbb{R}^D$ donde Ω es el espacio muestral.
- Esta función tiene asociada una **distribución de probabilidad** que le asigna masa a los eventos de Ω .
- Una variable aleatoria se dice **discreta** si solo puede tomar una cantidad finita de valores:

$$\text{supp}(x) = \{k_1, \dots, k_N\}$$

- Una variable aleatoria discreta tiene asociada una **función de masa** $p : \{k_1, \dots, k_N\} \rightarrow [0, 1]$:

$$p(k_n) = \text{Prob}(x = k_n), \quad n = 1, \dots, N$$

Variables aleatorias discretas

Ejemplos de variables aleatorias discretas:

- **Distribución de Bernoulli:** $x \sim \text{Bernoulli}(r)$ con $r \in [0, 1]$ si

$$\begin{aligned} p(x) &= \begin{cases} r & \text{si } x = 1 \\ 1 - r & \text{si } x = 0 \end{cases} \\ &= r^x(1 - r)^{1-x}, \quad x \in \{0, 1\} \end{aligned}$$

- **Distribución categórica:** $x \sim \text{Categórica}(r)$ con $r \in [0, 1]^N$ si

$$p(k_n) = r_n, \quad n = 1, \dots, N$$

Variables aleatorias continuas

- Una variable aleatoria se dice **continua** si tiene soporte $\text{supp}(x) \subset \mathbb{R}^D$ continuo.
- Una variable aleatoria continua tiene asociada una **función de densidad** $p : \mathbb{R}^D \rightarrow \mathbb{R}_+$:

$$\text{Prob}(x \in A) = \int_A p(x) dx, \quad A \subset \mathbb{R}^D$$

Variables aleatorias continuas

Ejemplos de variables aleatorias continuas:

- **Distribución gaussiana:** $x \sim \mathcal{N}(\mu, \sigma^2)$ con $\mu \in \mathbb{R}$ y $\sigma^2 > 0$ si

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

- **Distribución gaussiana en $\mathbb{R}^D$:** $x = (x_1, \dots, x_D) \sim \mathcal{N}(\mu, \Sigma)$ con $\mu \in \mathbb{R}^D$ y $\Sigma \in \mathcal{M}_{D,D}(\mathbb{R})$ simétrica y definida positiva si

$$p(x) = \frac{1}{\sqrt{(2\pi)^D \det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

Conceptos básicos

Para $(x, y) \sim p(x, y)$ se tienen los siguientes conceptos:

- Probabilidad condicional:

$$p(y|x) := \frac{p(x, y)}{p(x)}$$

- Independencia: $x \perp y$ si

$$p(x|y) = p(x) \quad \text{o, equivalentemente,} \quad p(x, y) = p(x)p(y)$$

- Marginalización:

$$p(x) = \int_{\mathbb{R}^D} p(x, y) \, dy$$

Para $x \sim p(x)$ se define la **esperanza** como

$$\mathbb{E}_{x \sim p(x)} [x] := \int_{\mathbb{R}^D} x p(x) dx$$

- Es lineal: $\mathbb{E} [\alpha x + \beta y] = \alpha \mathbb{E} [x] + \beta \mathbb{E} [y]$.
- Si x e y son independientes, $\mathbb{E} [xy] = \mathbb{E} [x] \mathbb{E} [y]$.
- Se puede factorizar:

$$\mathbb{E}_{p(x,y)} [f(x,y)] = \mathbb{E}_{p(y)} [\mathbb{E}_{p(x|y)} [f(x,y)]]$$

Para $x \sim p(x)$ se define la **varianza** como

$$\text{Var}(x) := \mathbb{E}_{p(x)} [(x - \mu)^2], \quad \text{donde} \quad \mu = \mathbb{E}_{p(x)} [x]$$

- $\text{Var}(x) \geq 0$ y $\text{Var}(x) = 0$ si y solo si x es constante.
- Si $x \perp y$, entonces para $\alpha, \beta \in \mathbb{R}$:

$$\text{Var}(\alpha x + \beta y) = \alpha^2 \text{Var}(x) + \beta^2 \text{Var}(y)$$

Redes neuronales

Definición general

- Todos los tipos de dato que se trabajarán pueden representarse como vectores en $\mathbb{R}^D$.
- Una **red neuronal** es una función $f : \mathbb{R}^D \rightarrow \mathbb{R}^K$ que se puede *adaptar* usando un **conjunto de entrenamiento**

$$\mathcal{D} = \{(x^1, y^1), \dots, (x^R, y^R)\} \subset \mathbb{R}^D \times \mathbb{R}^K$$

- Por lo general, una red neuronal es una composición de funciones de la forma

$$f(x) = f_N(f_{N-1}(\dots(f_1(x))\dots)),$$

donde $f_n : \mathbb{R}^{D_{n-1}} \rightarrow \mathbb{R}^{D_n}$ (con $D_0 = D$ y $D_N = K$) son los **bloques** que componen la red.

Redes fully-connected

Una **red fully connected** es un tipo de red neuronal donde cada bloque $f_n : \mathbb{R}^{D_{n-1}} \rightarrow \mathbb{R}^{D_n}$ es de la forma

$$f_n(x) = \Phi(A_n x + b_n).$$

- $A_n \in \mathcal{M}_{D_n, D_{n-1}}(\mathbb{R})$ y $b_n \in \mathbb{R}^{D_n}$ son los **parámetros** del bloque f_n que definen su comportamiento.
- $\Phi : \mathbb{R}^{D_n} \rightarrow \mathbb{R}^{D_n}$ es una **función de activación** que aplica una misma función $\phi : \mathbb{R} \rightarrow \mathbb{R}$ coordenada a coordenada:

$$\Phi(y) = (\phi(y_1), \dots, \phi(y_{D_n}))$$

- Una red neuronal puede recibir más entradas agregando más parámetros. Por ejemplo:

$$f_n(x, c) = \Phi(A_n x + B_n c + d_n),$$

El conjunto de parámetros $\Theta := \{\theta_1, \dots, \theta_N\}$ se suele elegir minimizando una **función de pérdida** $L : \mathbb{R}^K \times \mathbb{R}^K \rightarrow \mathbb{R}$ promediada sobre el conjunto de entrenamiento:

$$\min_{\Theta} \mathcal{L}(\mathcal{D}), \quad \text{donde} \quad \mathcal{L}(\mathcal{D}) = \frac{1}{R} \sum_{r=1}^R L(f(x_r), y_r)$$

Para esto, se utilizan algoritmos de optimización basados en gradiente, los cuales realizan iteraciones de la forma

$$\theta_n \leftarrow \theta_n - \lambda \nabla_{\theta_n} \mathcal{L}(\mathcal{D}), \quad n = 1, \dots, N$$

donde $\lambda > 0$ se denomina **tasa de aprendizaje**.

Ejemplo: clasificación con redes neuronales

Para la tarea de clasificación (x : imagen, y : clase):

- Se puede considerar que $p_{\text{data}}(y|x) \sim \text{Categórica}(r_{\text{data}})$, donde $r_{\text{data}} \in [0, 1]^K$ es un vector de probabilidades.
- $p_{\text{data}}(y|x)$ se aproxima con $p_{\theta}(y|x) \sim \text{Categórica}(r_{\theta}(x))$, donde r_{θ} es una red neuronal entrenada maximizando

$$\mathcal{L}(\mathcal{D}) = \frac{1}{R} \sum_{r=1}^R \log p_{\theta}(y^r|x^r)$$

- Para que r_{θ} sea un vector de probabilidades, se suele utilizar la función softmax: $\mathbb{R}^K \rightarrow [0, 1]^K$ en la salida:

$$\text{softmax}(l) := \left(\frac{e^{l_1}}{\sum_{k=1}^K e^{l_k}}, \dots, \frac{e^{l_K}}{\sum_{k=1}^K e^{l_k}} \right), \quad \text{para } l \in \mathbb{R}^K$$

En la próxima clase.

- Introducción a las redes bayesianas.
- Modelos de variable latente, modelos generativos condicionales, ejemplos.

Modelos Generativos Profundos

Clase 2: Repaso de probabilidad y redes neuronales