

Modelos Generativos Profundos

Clase 14: Autoencoders variacionales (parte II)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Evidence lower bound

Reparametrization trick

Interpolación en el espacio latente

Evidence lower bound

ELBO | Definición

Un **VAE** es un modelo de variable latente $p_\theta(x, z) = p_\theta(z)p_\theta(x|z)$, el cual utiliza una segunda distribución auxiliar, $q_\phi(z|x)$ para aproximar la posterior intractable $p_\theta(z|x)$.

Un VAE se entrena maximizando la **ELBO** media sobre un conjunto de datos de entrenamiento, $\mathcal{D} = \{x^1, \dots, x^N\} \subset \mathbb{R}^D$:

$$\max_{\theta, \phi} \frac{1}{N} \sum_{n=1}^N \text{ELBO}(x^n),$$

donde la ELBO (*evidence lower bound*) de una muestra $x \in \mathbb{R}^D$ se define como

$$\text{ELBO}(x) := \log p_\theta(x) - D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x))$$

Notar que $\text{ELBO}(x)$ es una cota inferior de la **evidencia** $\log p_\theta(x)$.

La ELBO se puede reescribir como:

$$\text{ELBO}(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{término de reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z))}_{\text{prior matching}}$$

Por lo tanto, se puede realizar la siguiente elección de distribuciones para hacer esta cantidad tratable:

- **Prior latente gaussiano:** $p_\theta(z) = p(z) = \mathcal{N}(0, I_L)$.
- **Posterior aproximada gaussiana:** $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$, donde $\mu_\phi : \mathbb{R}^D \rightarrow \mathbb{R}^L$ y $\sigma_\phi : \mathbb{R}^D \rightarrow \mathbb{R}_{++}^L$ son redes neuronales.
- **Verosimilitud gaussiana (caso continuo):** $p_\theta(x|z) = \mathcal{N}(\mu_\theta(z), \sigma_0^2 I_D)$, donde $\mu_\theta : \mathbb{R}^L \rightarrow \mathbb{R}^D$ es una red neuronal y $\sigma_0^2 > 0$ es un hiperparámetro fijo.

Dadas dos distribuciones gaussianas en $\mathbb{R}^L$, su divergencia de Kullback-Leibler tiene forma cerrada:

$$\begin{aligned} D_{\text{KL}}(\mathcal{N}(\mu_1, \Sigma_1) \parallel \mathcal{N}(\mu_2, \Sigma_2)) \\ = \frac{1}{2} \left[(\mu_1 - \mu_2)^\top \Sigma_2^{-1} (\mu_1 - \mu_2) + \text{traza}(\Sigma_1 \Sigma_2^{-1}) - L - \log |\det(\Sigma_1 \Sigma_2^{-1})| \right] \end{aligned}$$

Por lo tanto, considerando que $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$ y $p_\theta(z) \sim \mathcal{N}(0, \mathbf{I}_L)$, se tiene que

$$\begin{aligned} D_{\text{KL}}(q_\phi(z|x) \parallel p_\theta(z)) \\ = \frac{1}{2} (\|\mu_\phi(x)\|^2 + \|\sigma_\phi(x)\|^2) - \sum_{l=1}^L \log \sigma_\phi(x)_l + \text{constante} \end{aligned}$$

Dado que $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$, esta v.a. se puede reparametrizar esta usando el cambio de variable

$$z = \mu_\phi(x) + \sigma_\phi \odot \epsilon \quad \text{donde} \quad \epsilon \sim \mathcal{N}(0, I_L)$$

Luego, el término de reconstrucción se puede escribir como

$$\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] = \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I_L)} [\log p_\theta(x|\mu_\phi(x) + \sigma_\phi \odot \epsilon)]$$

Esta esperanza se puede aproximar usando Monte Carlo:

$$\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] \approx \frac{1}{K} \sum_{k=1}^K \log p_\theta(x|\mu_\phi(x) + \sigma_\phi(x) \odot \epsilon_k),$$

donde $\epsilon_k \sim \mathcal{N}(0, I_L)$ para $k \in \{1, \dots, K\}$.

Dado que $p_{\theta}(x|z) \sim \mathcal{N}(\mu_{\theta}(z), \sigma_0^2 \mathbf{I}_D)$:

$$p_{\theta}(x|z) = \frac{1}{\sqrt{(2\pi\sigma_0^2)^D}} \exp\left(-\frac{1}{2\sigma_0^2} \|x - \mu_{\theta}(z)\|^2\right)$$

Por lo tanto, el término de reconstrucción se reduce a una diferencia de cuadrados, siendo similar a la función objetivo que se utiliza en un AE clásico:

$$\log p_{\theta}(x|z) = -\frac{1}{2\sigma_0^2} \|x - \mu_{\theta}(z)\|^2 + \text{constante}$$

Reparametrization trick

Truco de la reparametrización

El gradiente de una esperanza puede moverse dentro de la esperanza siempre y cuando la distribución con respecto a la que se calcula la esperanza no dependa de la variable con respecto a la que se está calculando el gradiente:

$$\nabla_{\theta} \mathbb{E}_{p(x)}[f_{\theta}(x)] = \mathbb{E}_{p(x)}[\nabla_{\theta} f_{\theta}(x)]$$

Esta igualdad permite obtener estimadores insesgados del gradiente $\nabla_{\theta} f_{\theta}(x)$ usando una aproximación de Monte Carlo.

La igualdad anterior deja de ser cierta si $p(x)$ es una distribución que depende de θ , por lo que no es posible usarla para estimar el gradiente del término de reconstrucción.

Interpolación en el espacio latente

Interpolación en el espacio latente

Dadas dos muestras $x_0, x_1 \in \mathbb{R}^D$, una forma trivial de interpolar entre ellas es mediante la interpolación euclidiana

$$\tilde{x}_t = (1 - t)x_0 + tx_1, \quad \text{donde } t \in [0, 1]$$

Por lo general, esta interpolación genera muestras $\tilde{x}_t \in \mathbb{R}^D$ sin sentido cuando se busca interpretar a $\tilde{x}_t$ como una muestra proveniente de $p_{\text{data}}(x)$. Una interpolación en el espacio latente:

$$z_t = (1 - t)\text{encoder}(x_0) + t\text{encoder}(x_1)$$

De este modo, $x_t = \text{decoder}(z_t) \in \mathbb{R}^D$ es una muestra interpolada linealmente pero en el espacio latente del VAE.

En la próxima clase.

- VAEs para imágenes.
- Algunas variantes de VAEs.
- Manipulación de atributos.

Modelos Generativos Profundos

Clase 14: Autoencoders variacionales (parte II)