

Modelos Generativos Profundos

Clase 15: Autoencoders variacionales (parte III)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

VAEs para imágenes y generación condicional

Continuous Bernoulli

Manipulación de atributos

VAEs para imágenes y generación condicional

Un VAE necesita definir 3 distribuciones: un **encoder** $q_\phi(z|x)$, un **decoder** $p_\theta(x|z)$ y un **prior** $p(z)$.

Para el entrenamiento del encoder y del decoder se maximiza la **ELBO** esperada sobre un conjunto de datos de entrenamiento:

$$\begin{aligned}\text{ELBO}(x) &:= \log p_\theta(x) - D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x)) \\ &= \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))\end{aligned}$$

Para la generación, se realiza **ancestral sampling**: primero se genera $z \sim p(z)$ y luego se genera $x \sim p_\theta(x|z)$.

Notar que el proceso de generación no hace uso del encoder.

Elección de distribuciones

El término de prior matching $D_{\text{KL}}(q_\phi(z|x) \| p(z))$ en la ELBO motiva a considerar distribuciones gaussianas para el prior latente y para el encoder:

- $p(z) \sim \mathcal{N}(0, \mathbf{I}_L)$
- $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$

En cambio, la elección de la distribución $p_\theta(x|z)$ del encoder depende del tipo de datos que se esté modelando.

En particular, si los datos en $p_{\text{data}}(x)$ son de naturaleza continua, es usual considerar una **distribución gaussiana**:

$$p_\theta(x|z) \sim \mathcal{N}(\mu_\theta(z), \sigma_0^2 \mathbf{I}_D),$$

donde $\mu_\theta(z) \in \mathbb{R}^D$ es la salida de una red neuronal.

Elección de distribuciones

Si $p_{\text{data}}(x)$ es una distribución definida sobre imágenes, cada pixel $x_d \in [0, 1]$ (condicionado a z) se suele modelar como una **distribución Bernoulli** con parámetro $r_d = r_{\theta}(z)_d \in [0, 1]$:

$$p_{\theta}(x_d|z) = r_d^{x_d} \cdot (1 - r_d)^{1-x_d}$$

Luego, asumiendo una independencia condicional de los píxeles, la distribución asociada al decoder es

$$\begin{aligned}\log p_{\theta}(x|z) &= \sum_{d=1}^D \log p_{\theta}(x_d|z) \\ &= \sum_{d=1}^D (x_d \cdot \log r_d + (1 - x_d) \cdot \log(1 - r_d)),\end{aligned}$$

donde $r_{\theta}(z) = (r_1, \dots, r_D) \in [0, 1]^D$ es la salida de una red neuronal con activación sigmoideal.

VAE condicional

Al igual que toda red bayesiana, se puede extender la formulación original de un VAE a su **forma condicional**.

Si $y \sim p(y)$ es un factor condicionante (p.g. clase o descripción textual), entonces basta considerar las distribuciones condicionales

- **Encoder:** $q_{\phi}(z|x, y)$
- **Decoder:** $p_{\theta}(x|z, y)$
- **Prior:** $p(z|y)$.

Se suele considerar que $z \perp y$, por lo que $p(z|y) = p(z)$. En consecuencia, solo se deben modificar las redes neuronales asociadas al encoder y al decoder para que reciban la condición y como entrada adicional.

Continuous Bernoulli

Función de densidad

Si bien la formulación anterior es la más usada en VAEs para imágenes, es matemáticamente incorrecta ya que los píxeles están en el intervalo $[0, 1]$ y no en el conjunto discreto $\{0, 1\}$, por lo que no es correcto utilizar una distribución Bernoulli.

Para abordar este problema, se puede utilizar la distribución **Bernoulli continua**, la cual extiende el soporte de la distribución Bernoulli al intervalo $[0, 1]$:

$$x \sim \mathcal{CB}(r) \iff p(x) = C_r r^x (1-r)^{1-x} \quad \text{para } r \in (0, 1)$$

La constante de normalización $C_r = \int_0^1 r^x (1-r)^{1-x} dx \geq 2$ se puede obtener en forma cerrada.

ELBO para Bernoulli continua

Notar que $\log p_{CB}(x) = \log p_B(x) + \log C_r$, por lo que eligiendo $p_\theta(x|z)$ como un producto de Bernoulli's continuas, se tiene que:

$$\begin{aligned}\text{ELBO}_{CB}(x) &= \mathbb{E}_{q_\phi(z|x)} \left[\sum_{d=1}^D \log p_\theta(x_d|z) \right] - D_{\text{KL}}(q_\phi(z|x) \| p(z)) \\ &= \text{ELBO}_B(x) + \mathbb{E}_{q_\phi(z|x)} \left[\sum_{d=1}^D \log C_{r_d} \right]\end{aligned}$$

En particular, dado que $C_{r_d} > 1$, entonces $\text{ELBO}_B(x) < \text{ELBO}_{CB}(x)$. Es decir, usando continuous Bernoulli se obtiene una mejor cota inferior de la log-verosimilitud.

Ejemplos


Esta diferencia no es solo un error de formalidad, si no que induce errores significativos en la calidad de la generación:

data										
$\mathcal{CB}$ VAE										
$\mathcal{B}$ VAE										
$\mathcal{N}$ VAE										

Manipulación de atributos

Idea general

La continuidad del espacio latente permite modificar la intensidad de algún atributo de una muestra:



Si $\mathcal{X}$ es un conjunto de muestras desde $p_{\text{data}}(x)$, $\mathcal{X}^+ \subset \mathcal{X}$ es el subconjunto de muestras que poseen el atributo que se busca modificar y $\mathcal{X}^- \subset \mathcal{X}$ es el subconjunto de muestras que no poseen el atributo, entonces se pueden considerar los centroides

$$z^+ = \frac{1}{|\mathcal{X}^+|} \sum_{x \in \mathcal{X}^+} \text{encoder}(x), \quad z^- = \frac{1}{|\mathcal{X}^-|} \sum_{x \in \mathcal{X}^-} \text{encoder}(x)$$

De este modo, el vector $z_{\text{atributo}} = z^+ - z^- \in \mathbb{R}^L$ representa la **dirección latente** asociada al atributo. Luego, para $\lambda \in \mathbb{R}$ y para una muestra $x \sim p_{\text{data}}(x)$, la muestra

$$\tilde{x} = \text{decoder}(\text{encoder}(x) + \lambda z_{\text{atributo}})$$

corresponde a la muestra original x con el atributo amplificado ($\lambda > 0$) o disminuido ($\lambda < 0$).

En la próxima clase.

- β -VAE y VQ-VAE.
- Inception score (IS) y Fréchet inception distance (FID).
- 4º control de lectura.

Modelos Generativos Profundos

Clase 15: Autoencoders variacionales (parte III)