

Modelos Generativos Profundos

Clase 16: Autoencoders variacionales (parte IV)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

β -VAE

VQ-VAE

β -VAE

Interpretación de la ELBO

La ELBO de un VAE estándar es:

$$\text{ELBO}(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{término de reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z))}_{\text{prior matching}}$$

El **término de reconstrucción** fuerza a que el decoder aprenda a reconstruir bien los datos a partir de su representación latente dada por el encoder.

El **término de prior matching** fuerza a que la representación latente entregada por el encoder se parezca al prior $p_\theta(z)$, el cual se suele elegir como una distribución gaussiana isotrópica.

En particular, el término de prior matching fuerza a que las dimensiones latentes sean independientes entre sí.

Disentangled representations


En **representation learning**, una representación latente se dice **desacoplada** si cada dimensión de la representación codifica una característica semántica distinta de los datos, la cual se mantiene invariante ante cambios en otros factores latentes.

Una factorización latente desacoplada permite:

- Interpretar cada dimensión latente como una característica semántica de los datos.
- Controlar las características semánticas de los datos manipulando las dimensiones latentes correspondientes.

Si bien se podrían buscar representaciones desacopladas usando aprendizaje supervisado, es deseable lograrlo usando únicamente aprendizaje no supervisado.

Disentangled representations



Modificación de la ELBO

Una forma de lograr representaciones desacopladas es usar un β -VAE, el cual le da más importancia al término de prior matching en la ELBO:


$$\text{ELBO}_{\beta}(x) = \mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)] - \beta D_{\text{KL}}(q_{\phi}(z|x) \| p_{\theta}(z)) ,$$

El hiperparámetro $\beta \geq 0$ controla el grado de disentanglement:

- Si $\beta = 0$, se obtiene un autoencoder estándar sin regularización.
- Si $\beta = 1$, se recupera el VAE original.
- Si $\beta > 1$, se promueven representaciones latentes desacopladas.


El valor de β induce un trade-off entre la calidad de generación y el grado de disentanglement de la representación latente.

Ejemplo de juguete



Ejemplo en CelebA

En datasets más complejos, las representaciones desacopladas aprendidas se corresponden con factores latentes naturales para un humano:



VQ-VAE

Espacio latente discreto

Los VAEs con decoders muy potentes sufren del **colapso de la posterior**, donde el decoder aprende $p_{\text{data}}(x)$ ignorando la representación latente $z \in \mathbb{R}^L$ dada (i.e., $q_{\phi}(z|x) \approx p(z)$).

Un **vector quantized VAE (VQ-VAE)** propone utilizar un espacio latente discreto formado por un conjunto finito de vectores, $\{e_k\}_{k=1}^K \subset \mathbb{R}^L$, los cuales son aprendidos durante el entrenamiento:


- El encoder $q_{\phi}(z|x)$ mapea de manera determinista cada dato $x \in \mathbb{R}^D$ a uno de los vectores en el **codebook** $\{e_1, \dots, e_K\} \subset \mathbb{R}^L$.
- El decoder procesa el vector latente $e_k \in \mathbb{R}^L$ igual que en un VAE estándar.
- En una CNN, cada feature map (*pixel*) en la salida del encoder se cuantiza de manera independiente, usando el mismo codebook.

Encoder determinista

Para obtener el vector latente discreto asociado a una entrada, se sigue un enfoque tipo **K-means**, mapeando la salida de la red neuronal del encoder al vector más cercano en el codebook:

$$q_{\phi}(z|x) \sim \delta_{e_k}(z), \quad \text{donde} \quad k = \operatorname{argmin}_j \|z_e(x) - e_j\|$$

$z_e(x)$ es la salida continua de la red neuronal del encoder antes de la **cuantización**, la cual se denota como $z_q(x) = e_k$.



Función de pérdida

Un VQ-VAE considera una posterior $q_\phi(z|x)$ determinista, lo que evita el colapso de la posterior. Además, considerando un prior uniforme $p(z) \sim \text{Categórica}(\{e_1, \dots, e_k\})$, el término de prior matching se vuelve constante.

La función de pérdida del VQ-VAE es:

$$\mathcal{L}_{\text{VQ-VAE}}(x) = \log p(x|z_q(x)) + \|\text{sg}[z_e(x)] - e\|^2 + \beta \|z_e(x) - \text{sg}[e]\|^2,$$

donde $z_e(x)$ es la salida del encoder, $z_q(x)$ es su representación cuantizada, e es el codebook y $\text{sg}[\cdot]$ es la operación **stop-gradient**, que detiene el flujo de gradiente:

$$\text{sg}[u] = u \text{ durante el forward} \quad \text{y} \quad \frac{\partial \text{sg}[u]}{\partial u} = 0 \text{ durante el backward}$$

Función de pérdida

Los nuevos términos en la función de pérdida son los siguientes:

- El término $\| \text{sg}[z_e(x)] - e \|^2$ (**VQ loss**) actualiza solo el codebook e , moviendo cada vector e_k hacia los encodings z_e que se le asignan (similar a k-means).
- El término $\beta \|z_e(x) - \text{sg}[e]\|^2$ (**commitment loss**) actualiza solo el encoder, forzando a que sus encodings $z_e(x)$ se mantengan cerca de los vectores del codebook e (evita que los encodings crezcan sin límite).

En la próxima clase.

- Introducción a normalizing flows.

Modelos Generativos Profundos

Clase 16: Autoencoders variacionales (parte IV)