

Modelos Generativos Profundos

Clase 17: Flujos normalizantes (parte I)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Recuerdo de cosas previas

Flujos normalizantes

Recuerdo de cosas previas

Teorema del cambio de variables en probabilidades

Dada una variable aleatoria $X \sim p(x)$ en $\mathbb{R}$ y una función estrictamente creciente, $f : \mathbb{R} \rightarrow \mathbb{R}$, entonces se puede definir la variable aleatoria $Y = f(X)$, donde:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(f(X) \leq y) = \mathbb{P}(X \leq f^{-1}(y)) = F_X(f^{-1}(y))$$

derivando:

$$F'_Y(y) = F'_X(f^{-1}(y)) (f^{-1})'(y)$$

Además, dado que $(f^{-1})' = \frac{1}{f'(f^{-1})}$, se tiene que:

$$p_Y(y) = p_X(f^{-1}(y)) \cdot \frac{1}{f'(x)}, \quad \text{donde } x = f^{-1}(y)$$

Teorema del cambio de variables en probabilidades

De forma análoga se puede hacer lo mismo para $f : \mathbb{R} \rightarrow \mathbb{R}$ decreciente.

En general, si $f : \mathbb{R} \rightarrow \mathbb{R}$ es biyectiva y diferenciable, entonces el **teorema de cambio de variable** entrega la densidad de $Y = f(X)$:

$$p_Y(y) = p_X(f^{-1}(y)) \left| \frac{1}{f'(x)} \right|, \quad \text{donde } x = f^{-1}(y)$$

Este teorema puede ser extendido al caso multivariable, donde las variables aleatorias viven en $\mathbb{R}^D$. Para esto, es necesario recordar algunos conceptos de álgebra lineal y cálculo multivariable.

Función inversa y determinante

Dadas dos biyecciones $f, g : \mathbb{R}^D \rightarrow \mathbb{R}^D$, se tiene que:

- **Composición:** $g \circ f : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es otra biyección.
- **Inversa:** $(g \circ f)^{-1} = f^{-1} \circ g^{-1}$.

Dadas dos matrices cuadradas $A, B \in \mathcal{M}_{D,D}(\mathbb{R})$, se cumple que:

- **Inversa:** $(AB)^{-1} = B^{-1}A^{-1}$
- **Determinante:** $\det(AB) = \det(A) \det(B)$

Recordar que, para $A \in \mathcal{M}_{D,D}(\mathbb{R})$, la cantidad $\det(A) \in \mathbb{R}$ mide el cambio de volumen que produce la transformación $f(x) = Ax$.

Derivadas en cálculo multivariable

Para un **campo vectorial** $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ existen $n \times m$ derivadas parciales, $\frac{\partial f_i}{\partial x_j} : \mathbb{R} \rightarrow \mathbb{R}$ asociadas a él. La **matriz jacobiana** de f , $J_f(x) \in \mathcal{M}_{m,n}(\mathbb{R})$, almacena todas estas derivadas parciales:

$$J_f(x) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1}(x) & \frac{\partial f_1}{\partial x_2}(x) & \cdots & \frac{\partial f_1}{\partial x_n}(x) \\ \frac{\partial f_2}{\partial x_1}(x) & \frac{\partial f_2}{\partial x_2}(x) & \cdots & \frac{\partial f_2}{\partial x_n}(x) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1}(x) & \frac{\partial f_m}{\partial x_2}(x) & \cdots & \frac{\partial f_m}{\partial x_n}(x) \end{pmatrix} = \begin{pmatrix} \nabla f_1(x)^\top \\ \nabla f_2(x)^\top \\ \vdots \\ \nabla f_m(x)^\top \end{pmatrix}$$

Además, la **regla de la cadena** se extiende naturalmente:

$$J_{g \circ f}(x) = J_g(f(x)) J_f(x)$$

Cambio de variables en varias variables

Una función $f : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es un **difeomorfismo** si es biyectiva, diferenciable y su inversa f^{-1} también es diferenciable.

Si $X \sim p_X(x)$ es una variable aleatoria en $\mathbb{R}^D$ y $f : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es un difeomorfismo, entonces $Y = f(X)$ tiene densidad

$$p_Y(y) = p_X(f^{-1}(y)) |\det J_{f^{-1}}(y)|$$

Además, por teorema de la función inversa:

$$\det J_{f^{-1}}(y) = \frac{1}{\det J_f(x)}, \quad \text{donde } x = f^{-1}(y)$$

Flujos normalizantes

Dada una distribución base $p_z(z)$ y una distribución objetivo $p_{\text{data}}(x)$, el objetivo de la técnica de **flujos normalizantes** es encontrar un difeomorfismo $f : \mathbb{R}^D \rightarrow \mathbb{R}^D$ tal que $x = f(z)$ tenga distribución $p_x(x) \approx p_{\text{data}}(x)$ cuando se comienza con $z \sim p_z(z)$.

Usualmente, f se modela usando una red neuronal, la cual es entrenada usando el criterio de máxima verosimilitud, donde:

$$\log p_x(x) = \log p_z(z) - \log |\det J_f(z)|, \quad \text{con } z = f^{-1}(x)$$

Sin embargo, calcular $f^{-1}(x)$ y $\det J_f(z)$ de forma eficiente no es trivial si f es una red neuronal arbitraria.

Composición

Una forma de facilitar el cálculo es definir $f : \mathbb{R}^D \rightarrow \mathbb{R}^D$ como la composición de varias transformaciones más simples:

$$f(x) = (f_K \circ f_{K-1} \circ \cdots \circ f_1)(x)$$

Si cada $f_k : \mathbb{R}^D \rightarrow \mathbb{R}^D$ es un difeomorfismo, entonces f también lo es. Además, $f^{-1}(x) = (f_1^{-1} \circ f_2^{-1} \circ \cdots \circ f_K^{-1})(x)$.

Para $\log |\det J_f(z)|$ se tiene que:

$$\det J_f(z) = \prod_{k=1}^K \det J_{f_k}(z_{k-1})$$

donde $z_0 = z$ y $z_k = f_k(z_{k-1})$. Por lo tanto:

$$\log |\det J_f(z)| = \sum_{k=1}^K \log |\det J_{f_k}(z_{k-1})|$$

Dado un conjunto de entrenamiento $\mathcal{D} = \{x^n\}_{n=1}^N \subset \mathbb{R}^D$ de muestras generadas desde $p_{\text{data}}(x)$, se debe optimizar

$$\max_{\theta} \frac{1}{N} \sum_{n=1}^N \log p_x(x^n)$$

donde cada término de la suma se calcula como

$$\log p_x(x) = \log p_z(z_0) - \sum_{k=1}^K \log |\det J_{f_k}(z_{k-1})|,$$

donde la suma se realiza comenzando desde $z_K = x$ y calculando hacia atrás $z_{k-1} = f_k^{-1}(z_k)$, hasta llegar a $z_0 = f_1^{-1}(z_1)$.

En la próxima clase.

- Ejemplos de flujos normalizantes tratables.

Modelos Generativos Profundos

Clase 17: Flujos normalizantes (parte I)