

Modelos Generativos Profundos

Clase 22: Modelos de difusión (parte II)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Repaso DDPM

Reparametrizaciones equivalentes

Repaso DDPM

Procesos forward y backward

Un modelo de difusión define dos procesos:

- **Proceso forward:**

$$q(x_{0:T}) = q(x_0) \prod_{t=1}^T q(x_t|x_{t-1}), \quad \begin{cases} q(x_0) = p_{\text{data}}(x_0) \\ q(x_t|x_{t-1}) \sim \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I_D) \end{cases}$$

La secuencia $(\alpha_t)_{t=1}^T \subset (0, 1)$ se elige tal que $q(x_T) \approx p_{\text{prior}}(x_T)$.

- **Proceso backward:**

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t), \quad \begin{cases} p(x_T) = p_{\text{prior}}(x_T) \\ p_{\theta}(x_{t-1}|x_t) \sim \mathcal{N}(\mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t)) \end{cases}$$

Se suele fijar $\Sigma_{\theta}(x_t, t)$ a un valor conveniente, por lo que solo se debe entrenar la red neuronal $\mu_{\theta} : \mathbb{R}^D \times \{0, \dots, T\} \rightarrow \mathbb{R}^D$.

Entrenamiento

DDPM se entrena maximizando $\mathbb{E}_{p_{\text{data}}(x_0)} [\text{ELBO}(x_0)]$, donde

$$\text{ELBO}(x_0) := \log p_{\theta}(x_0) - D_{\text{KL}}(q(x_{1:T}|x_0) \| p_{\theta}(x_{1:T}|x_0))$$

Esta cantidad puede descomponerse como:

$$\mathbb{E}_{q(x_1|x_0)} [\log p_{\theta}(x_0|x_1)] - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)} [D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \| p_{\theta}(x_{t-1}|x_t))] + \text{cte.}$$

Todas las distribuciones involucradas son conocidas:

- $q(x_t|x_0) \sim \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I_D)$, donde $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s \in (0, 1)$.
- $q(x_{t-1}|x_t, x_0) \sim \mathcal{N}(\mu_q(x_0, x_t, t), \sigma_q^2(t) I_D)$, con μ_q y σ_q^2 conocidos.
- $p_{\theta}(x_{t-1}|x_t) \sim \mathcal{N}(\mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$, con $\Sigma_{\theta}(x_t, t) = \sigma_q^2(t) I_D$.

Desarrollando los términos anteriores, la ELBO se reduce a:

$$\text{ELBO}(x_0) = - \sum_{t=1}^T \frac{1}{2\sigma_q^2(t)} \mathbb{E}_{q(x_t|x_0)} [\|\mu_q(x_0, x_t, t) - \mu_\theta(x_t, t)\|^2] + \text{cte.}$$

En la práctica, se minimiza una función de pérdida simplificada:

$$\mathbb{E}_{p_{\text{data}}(x_0), t \sim \text{Uniforme}(\{1, \dots, T\}), q(x_t|x_0)} [\|\mu_q(x_0, x_t, t) - \mu_\theta(x_t, t)\|^2]$$

Con el modelo entrenado, se pueden generar nuevas muestras mediante **ancestral sampling**, comenzando desde $x_T \sim p_{\text{prior}}(x_T)$ y muestreando sucesivamente $x_{t-1} \sim p_\theta(x_{t-1}|x_t)$ para $t \in \{T, \dots, 1\}$.

Reparametrizaciones equivalentes

Es usual **reparametrizar** la red neuronal $\mu_{\theta}(x_t, t)$ para que, en vez de aprender $\mu_q(x_0, x_t, t)$, aprenda otra cantidad relacionada.

Veremos tres reparametrizaciones usuales:

- **x_0 -prediction:** aprender a predecir la muestra original x_0 .
- **ϵ -prediction:** aprender a predecir el ruido ϵ_t inyectado a x_0 para obtener x_t .
- **Score-prediction:** aprender a predecir el score $\nabla_{x_t} \log q(x_t)$.

En todos los casos la idea es reescribir $\mu_q(x_0, x_t, t)$ para que la red neuronal aprenda solo los términos desconocidos.

Dado que $\mu_q(x_0, x_t, t) = c_1(t)x_0 + c_2(t)x_t$, entonces

$$\tilde{x}_0 = \frac{1}{c_1(t)}\mu_\theta(x_t, t) - \frac{c_2(t)}{c_1(t)}x_t$$

puede verse como una estimación de la muestra $x_0 \sim p_{\text{data}}(x_0)$ a la que se le inyectó el ruido.

Más aún, se puede reparametrizar la red neuronal $\mu_\theta(x_t, t)$ como $\mu_\theta(x_t, t) = c_1(t)x_\theta(x_t, t) + c_2(t)x_t$, donde $x_\theta(x_t, t)$ se entrena para aprender directamente x_0 en lugar de μ_q . En este caso:

$$\text{ELBO}(x_0) = \sum_{t=1}^T \frac{c_1^2(t)}{2\sigma_q^2(t)} \mathbb{E}_{q(x_t|x_0)} [\|x_0 - x_\theta(x_t, t)\|^2] + \text{cte.}$$

Otra reparametrización posible es predecir directamente el ruido ϵ_t inyectado a la muestra x_0 para obtener x_t .

Dado que $x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t$, entonces

$$x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} x_t - \frac{\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}} \epsilon(x_0, x_t, t)$$

De este modo, sustituyendo en $\mu_q(x_0, x_t, t) = c_1(t)x_0 + c_2(t)x_t$:

$$\mu_q(x_0, x_t, t) = \left(\frac{c_1(t)}{\sqrt{\bar{\alpha}_t}} + c_2(t) \right) x_t - \frac{c_1(t)\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}} \epsilon(x_0, x_t, t)$$

La igualdad anterior permite reparametrizar $\mu_\theta(x_t, t)$ como

$$\mu_\theta(x_t, t) = \left(\frac{c_1(t)}{\sqrt{\bar{\alpha}_t}} + c_2(t) \right) x_t - \frac{c_1(t)\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}} \epsilon_\theta(x_t, t),$$

donde $\epsilon_\theta(x_t, t)$ se entrena para predecir el ruido inyectado a x_0 para obtener x_t . En este caso:

$$\text{ELBO}(x_0) = - \sum_{t=1}^T \frac{c_1^2(t)(1 - \bar{\alpha}_t)}{2\sigma_q^2(t)\bar{\alpha}_t} \mathbb{E}_{q(x_t|x_0)} [\|\epsilon(x_0, x_t, t) - \epsilon_\theta(x_t, t)\|^2] + \text{cte.}$$

Esta reparametrización es la más utilizada en la práctica ya que un ruido gaussiano es más fácil de aprender que una imagen x_0 o una media μ_q . Notar que también permite estimar x_0 .

Una de las reparametrizaciones más importantes consiste en aprender el **score** $\nabla_{x_t} \log q(x_t)$ en vez de μ_q, x_0 o ϵ_t . Esto permite:

- Conectar los DMs con los modelos basados en score.
- Utilizar la técnica de **guidance** para generación condicional.
- Formular modelos de difusión a tiempo continuo usando SDEs.

Para esto, es necesario utilizar una propiedad de las distribuciones gaussianas conocida como **fórmula de Tweedie**.

Si $p(y|x) \sim \mathcal{N}(x, \sigma^2 I_D)$ es una distribución gaussiana con media $x \sim p(x)$ desconocida. Entonces, para una muestra $y \sim p(y|x)$:

$$\mathbb{E}_{p(x|y)}[x] = y + \sigma^2 \nabla_y \log p(y)$$

La expresión del lado derecho puede verse como una corrección del estimador de máxima verosimilitud de la media de $p(y|x)$, el cual es simplemente la muestra observada y .

Bajo esta interpretación, el término $\sigma^2 \nabla_y \log p(y)$ empuja la estimación hacia el centro, dependiendo del valor de $\nabla_y \log p(y)$.

Dado que $q(x_t|x_0) \sim \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t) I_D)$, la fórmula de Tweedie indica que

$$\sqrt{\bar{\alpha}_t} \underbrace{\mathbb{E}_{q(x_0|x_t)}[x_0]}_{x_0} = x_t + (1 - \bar{\alpha}_t) \nabla_{x_t} \log q(x_t)$$

Por lo tanto, $x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} x_t + \frac{1-\bar{\alpha}_t}{\sqrt{\bar{\alpha}_t}} \nabla_{x_t} \log q(x_t)$.

Esto puede sustituirse en $\mu_q(x_0, x_t, t) = c_1(t)x_0 + c_2(t)x_t$:

$$\mu_q(x_0, x_t, t) = \left(\frac{c_1(t)}{\sqrt{\bar{\alpha}_t}} + c_2(t) \right) x_t + \frac{c_1(t)(1 - \bar{\alpha}_t)}{\sqrt{\bar{\alpha}_t}} \nabla_{x_t} \log q(x_t)$$

La igualdad anterior permite reparametrizar $\mu_\theta(x_t, t)$ como

$$\mu_\theta(x_t, t) = \left(\frac{c_1(t)}{\sqrt{\bar{\alpha}_t}} + c_2(t) \right) x_t + \frac{c_1(t)(1 - \bar{\alpha}_t)}{\sqrt{\bar{\alpha}_t}} s_\theta(x_t, t)$$

donde la red neuronal $s_\theta(x_t, t)$ se entrena para predecir el score $\nabla_{x_t} \log q(x_t)$. En este caso:

$$\text{ELBO}(x_0) = - \sum_{t=1}^T \frac{c_1^2(t)(1 - \bar{\alpha}_t)^2}{2\sigma_q^2(t)\bar{\alpha}_t} \mathbb{E}_{q(x_t|x_0)} [\|\nabla_{x_t} \log q(x_t) - s_\theta(x_t, t)\|^2] + \text{cte.}$$

En particular, los DMs pueden verse como un caso particular de **denoising score-matching** con varios niveles de ruido.

Conclusiones

- En todos los casos, la ELBO sigue siendo una suma ponderada de errores cuadráticos medios entre la cantidad verdadera y la estimada por la red neuronal.
- Igual que en la formulación original (μ_q -prediction), los ponderadores de la ELBO suelen ser ignorados en la práctica.
- Todas las reparametrizaciones son equivalentes entre sí. En particular, cualquiera de las reparametrizaciones permite estimar la media μ_q , la imagen original x_0 , el ruido ϵ_t y el score $\nabla_{x_t} \log q(x_t)$.

En la próxima clase.

- Generación condicional y guidance.
- Algunos DMs famosos.
- Uso de GPU en la nube.

Modelos Generativos Profundos

Clase 22: Modelos de difusión (parte II)