

Modelos Generativos Profundos

Clase 13: Redes generativas adversarias (parte III)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Image-to-image translation

Propiedades de las GANs


Distancia de Wasserstein

Métricas de evaluación

Image-to-image translation

Image-to-image translation

Image-to-image translation (I2IT) es una tarea de generación condicional donde, dada una imagen $x \in \mathcal{X}$ perteneciente un dominio, se busca generar una imagen $y \in \mathcal{Y}$ (en otro dominio) que preserve la estructura de x pero con apariencia de $\mathcal{Y}$.




Se verán dos enfoques basados en GANs.

Dado un dataset de pares de entrenamiento,

$$\mathcal{D} = \{(x^n, y^n)\}_{n=1}^N \sim p_{\text{data}}(x, y),$$

con $x \in \mathcal{X}$ la imagen de entrada e $y \in \mathcal{Y}$ su imagen target, **Pix2Pix** aborda el problema de I2IT utilizando una CGAN que penaliza la distancia entre la imagen generada y la target:

$$\begin{aligned}\mathcal{L}_{\text{pix2pix}}(\theta, \phi) = & \mathbb{E}_{p(x) p_{\text{data}}(y|x)} [\log D_{\phi}(x, y)] \\ & + \mathbb{E}_{p(x) p(z)} [\log(1 - D_{\phi}(x, G_{\theta}(x, z)))] \\ & + \lambda \mathbb{E}_{p(x) p_{\text{data}}(y|x) p(z)} [\|y - G_{\theta}(x, z)\|_1].\end{aligned}$$



Las arquitecturas utilizadas por Pix2Pix son las siguientes:



- **Generador:** U-Net. Permite preservar información fina de la imagen; necesario para tareas donde la entrada y salida están alineadas.
- **Discriminador:** PatchGAN. Clasifica como real/sintético evaluando parches individuales de la imagen. Permite capturar detalles de alta frecuencia (texturas).

CycleGAN extiende Pix2Pix al caso **no supervisado**, aprendiendo una traducción bidireccional entre los dominios $\mathcal{X}$ e $\mathcal{Y}$ sin requerir pares alineados.

Para esto, CycleGAN considera dos GANs, $G_{\mathcal{X} \rightarrow \mathcal{Y}}$ y $G_{\mathcal{Y} \rightarrow \mathcal{X}}$, entrenadas simultáneamente, y agrega una restricción de **consistencia cíclica** que fuerza a los generadores a ser inversos aproximados entre sí:

$$G_{\mathcal{Y} \rightarrow \mathcal{X}}(G_{\mathcal{X} \rightarrow \mathcal{Y}}(x)) \approx x \quad \text{y} \quad G_{\mathcal{X} \rightarrow \mathcal{Y}}(G_{\mathcal{Y} \rightarrow \mathcal{X}}(y)) \approx y.$$

CycleGAN | Consistencia cíclica



Para inducir esta condición, la **cycle-consistency loss** penaliza el error absoluto de las discrepancias:

$$\begin{aligned}\mathcal{L}_{\text{cyc}} = & \mathbb{E}_{p_{\text{data}}(x)}[\|G_{Y \rightarrow X}(G_{X \rightarrow Y}(x)) - x\|_1] \\ & + \mathbb{E}_{p_{\text{data}}(y)}[\|G_{X \rightarrow Y}(G_{Y \rightarrow X}(y)) - y\|_1].\end{aligned}$$

De esta forma, la función objetivo de CycleGAN combina las dos pérdidas adversariales y el término de consistencia cíclica:

$$\mathcal{L}_{\text{CycleGAN}} = \mathcal{L}_{\text{GAN}}(G_{X \rightarrow Y}, D_Y) + \mathcal{L}_{\text{GAN}}(G_{Y \rightarrow X}, D_X) + \lambda \mathcal{L}_{\text{cyc}},$$

CycleGAN | Reconstrucción


Input x



Output $G(x)$



Reconstruction $F(G(x))$



Propiedades de las GANs

Relación con la divergencia de Jensen-Shannon

El problema de optimización estándar de una GAN es

$$\min_{\theta} \max_{\phi} \mathcal{L}_{\text{GAN}}(\theta, \phi) = \mathbb{E}_{p_{\text{data}}}[\log D_{\phi}(x)] + \mathbb{E}_{p_{\theta}}[\log(1 - D_{\phi}(x))].$$

Para un generador G_{θ} fijo, el discriminador óptimo asociado es

$$D_{\phi^*}(x) = \frac{p_{\text{data}}(x)}{p_{\text{data}}(x) + p_{\theta}(x)}.$$

Luego, sustituyendo D_{ϕ^*} , la pérdida del generador se reduce a

$$\mathcal{L}_{\text{GAN}}(\theta, \phi^*) = 2 \text{JSD}(p_{\text{data}} \parallel p_{\theta}) - \log 4.$$

Es decir, el problema minimax de una GAN *equivale* al problema

$$\min_{\theta} \text{JSD}(p_{\text{data}} \parallel p_{\theta}) := D_{\text{KL}}\left(p_{\text{data}} \parallel \frac{p_{\text{data}} + p_{\theta}}{2}\right) + D_{\text{KL}}\left(p_{\theta} \parallel \frac{p_{\text{data}} + p_{\theta}}{2}\right).$$

Limitaciones de las GANs

- El generador concentra masa en unas pocas modas de p_{data} , perdiendo diversidad (**mode collapse**).
- Si los soportes de p_{data} y p_{θ} son disjuntos, entonces $\text{JSD}(p_{\text{data}} \| p_{\theta})$ es constante, por lo que su gradiente con respecto a θ es nulo.
- El problema minimax es no convexo/cóncavo, por lo que el entrenamiento usualmente es inestable.
- La pérdida del discriminador no mide la calidad del generador, lo que dificulta el monitoreo y la comparación de modelos.

Distancia de Wasserstein

Earth mover problem


El problema de **transporte óptimo** consiste en trasladar de forma eficiente el cobre producido por N minas (cada mina ubicada en un punto $x_n \in \mathbb{R}^2$ y produciendo p_n toneladas) a M fábricas (cada una ubicada en $y_m \in \mathbb{R}^2$ y con demanda de q_m toneladas):

$$\min_{\gamma \in \Pi(p,q)} \sum_{n=1}^N \sum_{m=1}^M \gamma_{nm} c(x_n, y_m),$$

donde $c(x_n, y_m)$ es el costo de transportar una unidad de cobre desde la mina n hasta la fábrica m .

$\Pi(p, q) = \{\gamma \in \mathcal{M}_{N,M}(\mathbb{R}) : \sum_{m=1}^M \gamma_{nm} = p_n, \sum_{n=1}^N \gamma_{nm} = q_m\}$ es el conjunto de **planes de transporte** (matrices) factibles.

Earth mover problem




Extensión a distribuciones de probabilidad

Normalizando la producción y demanda a 1, el problema de transporte óptimo se puede reformular y extender a un problema de transporte entre distribuciones de probabilidad.

En este contexto, el problema anterior se llama **problema de Kantorovich**, y su solución resulta ser una **métrica** sobre (un subconjunto de) el espacio de distribuciones de probabilidad, conocida como **distancia de Wasserstein**.

Más aún, esta métrica tiene buenas propiedades que hacen que la minimización de $W_p(p_{\text{data}}, p_{\theta})$ sea adecuada para entrenar y evaluar modelos generativos.

Extensión a distribuciones de probabilidad



La **distancia de Wasserstein** (de orden p) entre dos distribuciones de probabilidad, $\mu, \nu \in \mathcal{P}(\mathbb{R}^D)$, se define como

$$W_p(\mu, \nu) := \left(\inf_{\gamma \in \Pi(\mu, \nu)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|^p] \right)^{1/p},$$


donde $\Pi(\mu, \nu) \subset \mathcal{P}(\mathbb{R}^D \times \mathbb{R}^D)$ es el conjunto de distribuciones conjuntas con marginales μ y ν .

El caso $p = 2$ se conoce como **distancia de Fréchet** (se utiliza en el cálculo de la FID), mientras que el caso $p = 1$ se conoce como **distancia de Kantorovich-Rubinstein** (se utiliza en WGAN).

La distancia de Wasserstein W_p tiene buenas propiedades:

- Está consciente de la geometría del espacio subyacente donde están definidas las distribuciones de probabilidad.
- Bajo ciertas condiciones, la función $\theta \mapsto W_p(p_{\text{data}}, p_{\theta})$ es continua y diferenciable.
- A diferencia de la KL o la JSD, proporciona gradientes informativos incluso cuando los soportes de p_{data} y p_{θ} son disjuntos.
- Es equivalente a una noción de convergencia importante en teoría de la probabilidad. En particular, está muy estudiada.

Extensión a distribuciones de probabilidad



Para el caso $p = 1$ es posible obtener una **formulación dual** del problema de transporte óptimo:

$$W_1(\mu, \nu) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim \mu}[f(x)] - \mathbb{E}_{x \sim \nu}[f(x)],$$

donde el supremo es sobre funciones 1-Lipschitz.

Notar que la función objetivo es similar a la que se optimiza en una GAN, por lo que se puede optimizar W_1 de forma análoga.

El modelo **Wasserstein GAN** (WGAN) aprovecha esta conexión para entrenar una GAN que minimice directamente $W_1(p_{\text{data}}, p_{\theta})$ en vez de la JSD.

Dada la dualidad de Kantorovich-Rubinstein,

$$W_1(p_{\text{data}}, p_{\theta}) = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p_{\text{data}}} [f(x)] - \mathbb{E}_{x \sim p_{\theta}} [f(x)],$$

la WGAN parametriza f con un **crítico** $D_{\phi} : \mathbb{R}^D \rightarrow \mathbb{R}$ que se entrena en conjunto con un generador $G_{\theta} : \mathbb{R}^L \rightarrow \mathbb{R}^D$ mediante

$$\min_{\theta} \max_{\phi} \mathcal{L}_{WGAN}(\theta, \phi) = \mathbb{E}_{p_{\text{data}}} [D_{\phi}(x)] - \mathbb{E}_{p(z)} [D_{\phi}(G_{\theta}(z))]$$

En cambio, la condición $\|D_{\phi}\|_L \leq 1$ se impone mediante técnicas como **weight clipping** o **penalización de gradiente**.

Se tienen las siguientes observaciones:

- El crítico D_ϕ ya no entrega una probabilidad, sino que es una función de puntuación que asigna valores altos a muestras reales y bajos a muestras sintéticas.
- El entrenamiento de WGAN es más estable que el de una GAN estándar. Además, el valor de la función objetivo correlaciona bien con la calidad de las muestras, sirviendo como una métrica de monitoreo útil.
- En general, siempre es preferible minimizar $W_1(p_{\text{data}}, p_\theta)$ sobre minimizar, por ejemplo, la KL. Sin embargo, a diferencia de la KL, W_p suele ser difícil de computar.

Métricas de evaluación

Inception Score

El **inception score** (IS) es una métrica de evaluación para generación de imágenes que utiliza una CNN **Inception** preentrenada como un clasificador $x \mapsto p(y|x)$ sobre ImageNet.

IS se basa en dos criterios:

- **Reconocibilidad:** la distribución $p(y|x)$ debe estar concentrada en pocas clases. Esto indica que la imagen generada es de alta calidad y pertenece a una clase específica.
- **Diversidad:** la marginal $p(y)$ debe ser lo más uniforme posible. Esto indica que el modelo cubre una amplia variedad de clases, evitando el mode collapse interclase.

Inception Score

Motivado por los criterios anteriores, el IS de una distribución generativa p_θ se define como la **información mútua** entre y e x :

$$\text{IS}(p_\theta) := \exp(\mathbb{E}_{x \sim p_\theta} [D_{\text{KL}}(p(y|x) \parallel p(y))]) ,$$

donde $p(y) = \mathbb{E}_{x \sim p_\theta} [p(y|x)]$ se aproxima por Monte Carlo utilizando muestras generadas desde p_θ .

En consecuencia, un valor de IS alto indica que las imágenes generadas son de alta calidad y diversas.

La limitación principal de IS es que evalúa p_θ sin considerar p_{data} en su evaluación.

Fréchet Inception Distance

La **Fréchet inception distance** (FID) compara las distribuciones p_{data} y p_{θ} mediante la distribución de sus **feature maps** respectivos obtenidos a partir de Inception. Para esto:

- Para cada imagen x (real o sintética) se extraen sus feature maps $\varphi(x)$ utilizando Inception.
- Por conveniencia, se asume que ambas distribuciones de features son gaussianas: $p_{\text{data}}(\varphi) \approx \mathcal{N}(\mu_r, \Sigma_r)$ y $p_{\theta}(\varphi) \approx \mathcal{N}(\mu_g, \Sigma_g)$.
- Se estiman los parámetros de las gaussianas por MLE.
- Finalmente, se calcula la distancia de Fréchet entre ambas gaussianas, la cual tiene una forma cerrada.

Fréchet Inception Distance

Considerando la fórmula de la distancia de Fréchet entre gaussianas, la FID puede calcularse de forma eficiente como

$$\begin{aligned}\text{FID}(p_{\text{data}}, p_{\theta})^2 &:= W_2^2(\mathcal{N}(\mu_r, \Sigma_r), \mathcal{N}(\mu_g, \Sigma_g)) \\ &= \|\mu_r - \mu_g\|_2^2 + \text{tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}\right).\end{aligned}$$

Valores de FID bajos indican mayor similitud perceptual con los datos reales.

En general, se suele considerar que FID es la métrica estándar para comparar modelos generativos de imágenes. Sin embargo, la suposición gaussiana es falsa en general, y además combina calidad y diversidad en un único escalar.

En la próxima clase:

- Autoencoders clásicos.
- Introducción a los autoencoders variacionales.

Modelos Generativos Profundos

Clase 13: Redes generativas adversarias (parte III)