

Modelos Generativos Profundos

Clase 2: Repaso de conceptos previos

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Probabilidades

Redes neuronales

Probabilidades

Variables aleatorias

Una **v.a.** x es una función que puede tomar distintos valores de acuerdo a una **distribución de probabilidad** $p(x)$.

Dependiendo de la naturaleza de la v.a., $p(x)$ se interpreta de dos formas distintas:

- **Variable discreta:** $p(x)$ es una función de masa.
- **Variable continua:** $p(x)$ es una función de densidad.

El **soporte** de la v.a., $\text{supp}(x) := \{x : p(x) > 0\}$, indica los distintos valores que una v.a. puede tomar.

Variables aleatorias discretas

Si $x \sim p(x)$ es una v.a. discreta con $\text{supp}(x) = \{k_1, \dots, k_N\}$, entonces su **función de masa** $p : \{k_1, \dots, k_N\} \rightarrow [0, 1]$ indica

$$\text{Prob}(x = k_n) = p(k_n)$$

Por definición de medida de probabilidad, es necesario que:

- $p(k_n) \geq 0$, para todo $n \in \{1, \dots, N\}$.
- $\sum_{n=1}^N p(k_n) = 1$.

Variables aleatorias discretas

En el caso discreto se pueden almacenar todas las salidas de $p(x)$ en un **vector de probabilidades** $(p(k_1), \dots, p(k_N)) \in [0, 1]^N$.

El conjunto de vectores de probabilidades de largo N se denomina **N -símplex**:

$$\Delta^N := \left\{ (p_1, \dots, p_N) \in \mathbb{R}^N : \left(\sum_{n=1}^N p_n = 1 \right) \wedge (p_n \geq 0, \forall n \in \{1, \dots, N\}) \right\}$$

Distribución de Bernoulli

La distribución discreta más simple es la **distribución de Bernoulli**.

Se dice que $x \sim \text{Bernoulli}(r)$, con $r \in [0, 1]$, si $\text{supp}(x) = \{0, 1\}$ con $\text{Prob}(x = 1) = r$ y $\text{Prob}(x = 0) = 1 - r$, i.e.:




$$p(x) = \begin{cases} r & \text{si } x = 1 \\ 1 - r & \text{si } x = 0 \end{cases}$$
$$= r^x(1 - r)^{1-x}, \quad x \in \{0, 1\}$$

Distribución categórica

La distribución de Bernoulli se puede extender al caso multiclase, dando lugar a la **distribución categórica**.

Se dice que $x \sim \text{Categórica}(r)$, con $r \in \Delta^N$, si:

- $\text{supp}(x) = \{k_1, \dots, k_N\}$.
- $\text{Prob}(x = k_n) = r_n$.



Variables aleatorias continuas

Si $x \sim p(x)$ es una v.a. continua, su **función de densidad** $p : \mathbb{R}^D \rightarrow \mathbb{R}_+$ permite calcular la probabilidad de que x esté en un cierto conjunto $A \subset \mathbb{R}^D$ mediante integración:

$$\text{Prob}(x \in A) = \int_A p(x) \, dx$$

Por definición de medida de probabilidad, es necesario que:


- $p(x) \geq 0$, para todo $x \in \mathbb{R}^D$.
- $\int_{\mathbb{R}^D} p(x) \, dx = 1$.

Notar que aquí no se cumple necesariamente que $p(x) \leq 1$.

Distribución gaussiana

Para $\mu \in \mathbb{R}$ y $\sigma^2 > 0$, se dice que $x \sim \mathcal{N}(\mu, \sigma^2)$ es una v.a. **gaussiana** o **normal** (unidimensional) si tiene densidad

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$



Distribución gaussiana

La distribución gaussiana tiene las siguientes propiedades:

- Es una distribución unimodal de cola ligera.
- Si $x \sim \mathcal{N}(\mu, \sigma^2)$, entonces $ax + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.
- Si $x_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ y $x_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$, entonces

$$x_1 + x_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$


- $\log p(x)$ es una función cóncava.
- El promedio de v.a. i.i.d.s converge a una v.a. gaussiana.
- Es la distribución de máxima entropía dentro de la familia de distribuciones con soporte $(-\infty, \infty)$ y varianza finita.

Distribución gaussiana multivariada

Es posible extender la distribución gaussiana al caso multidimensional.

Si $\mu = (\mu_1, \dots, \mu_D) \in \mathbb{R}^D$ y $\Sigma \in \mathcal{M}_{D,D}(\mathbb{R})$ es una matriz simétrica definida positiva, entonces $x \sim \mathcal{N}(\mu, \Sigma)$ si tiene densidad

$$p(x) = \frac{1}{\sqrt{(2\pi)^D \det(\Sigma)}} \exp \left(-\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right)$$



Distribución condicional y dependencia

Dadas dos v.a., $x \sim p(x)$ e $y \sim p(y)$, se denotará por $p(x|y)$ a la **distribución condicional** que sigue la v.a. x cuando se conoce (o se fija) el valor que toma la v.a. y :

$$p(x|y) := \frac{p(x,y)}{p(y)}$$

Las v.a. $x \sim p(x)$ e $y \sim p(y)$ se dicen **independientes** ($x \perp y$) si

$$p(x|y) = p(x) \quad \text{o, equivalentemente,} \quad p(x,y) = p(x)p(y)$$

La independencia es simétrica: si $x \perp y$, entonces $y \perp x$.


Si dos v.a. no son independientes, se dicen **dependientes**.

Marginalización


Dada una **distribución conjunta** $p(x, y)$, es posible obtener la distribución $p(x)$ mediante **marginalización**:

$$p(x) = \sum_{n=1}^N p(x, y = y_k) \quad \text{o bien} \quad p(x) = \int_{\mathbb{R}^D} p(x, y) dy$$

$\mu = [-1, 2], \Sigma = [[3.0, 0.0], [0.0, 1.0]]$



$\mu = [-1, 2], \Sigma = [[3.0, 1.0], [1.0, 1.0]]$



Notar que la distribución conjunta $p(x, y)$ contiene más información que las distribuciones individuales $p(x)$ y $p(y)$.

Por definición de probabilidad condicional, es directo que

$$p(y|x) = \frac{p(y)p(x|y)}{p(x)}$$

Este resultado se conoce como **regla de Bayes**.

Esta propiedad se puede extender a un conjunto de variables aleatorias. Por inducción se prueba que

$$p(x_1, \dots, x_N) = p(x_1) \prod_{n=2}^N p(x_n | x_1, \dots, x_{n-1})$$

Este resultado se conoce como **regla de la cadena**.

Esperanza

Dada una v.a. $x \sim p(x)$, su **esperanza** corresponde al valor que se espera obtener al promediar muestras generadas desde x .

Si $x \sim p(x)$ es una v.a. discreta con $\text{supp}(x) = \{k_1, \dots, k_N\}$:

$$\mathbb{E}_{x \sim p(x)} [x] := \sum_{n=1}^N k_n p(k_n)$$

En general, para una función $f : \{k_1, \dots, k_N\} \rightarrow \mathbb{R}$:

$$\mathbb{E}_{x \sim p(x)} [f(x)] = \sum_{n=1}^N f(k_n) p(k_n)$$

En el caso continuo, la esperanza de una v.a. $x \sim p(x)$ se define de forma análoga:

$$\mathbb{E}_{x \sim p(x)} [x] := \int_{\mathbb{R}^D} x p(x) dx$$

De forma general, para $f : \mathbb{R}^D \rightarrow \mathbb{R}$:

$$\mathbb{E}_{x \sim p(x)} [f(x)] = \int_{\mathbb{R}^D} f(x) p(x) dx$$

Por otro lado, se suele denotar $\mathbb{E}_{x \sim p(x)} [x]$ como $\mathbb{E}_{p(x)} [x]$ para no sobrecargar la notación.

Si una v.a. no participa dentro del argumento, se puede omitir:

$$\mathbb{E}_{p(x,y)}[f(x)] = \mathbb{E}_{p(x)}[f(x)]$$

Además, la esperanza es un operador lineal:

$$\mathbb{E}_{p(x,y)}[\alpha x + \beta y] = \alpha \mathbb{E}_{p(x)}[x] + \beta \mathbb{E}_{p(y)}[y]$$

Por otro lado, la esperanza se puede factorizar de forma similar a la distribución conjunta:

$$\mathbb{E}_{p(x,y)}[f(x,y)] = \mathbb{E}_{p(y)} [\mathbb{E}_{p(x|y)}[f(x,y)]]$$

Si $x \sim p(x)$ es una v.a. desde la cual es fácil generar muestras, la ley de grandes números permite aproximar una esperanza:

$$\mathbb{E}_{p(x)}[f(x)] \approx \frac{1}{N} \sum_{n=1}^N f(x^n),$$

donde $x^n \sim p(x)$ para todo $n \in \{1, \dots, N\}$.

Esta aproximación se suele llamar **estimación de Monte Carlo**.

Varianza y covarianza

La **varianza** de una v.a. $x \sim p(x)$ en $\mathbb{R}$ corresponde a la desviación cuadrática media de la v.a. con respecto a su media $\mu = \mathbb{E}_{p(x)}[x]$:

$$\text{Var}(x) := \mathbb{E}_{p(x)} [(x - \mu)^2]$$

Este concepto se puede extender al concepto de covarianza. Si $x \sim p(x)$ e $y \sim p(y)$ son dos v.a. en $\mathbb{R}$ con medias μ_x y μ_y :

$$\text{Cov}(x, y) := \mathbb{E}_{p(x,y)} [(x - \mu_x)(y - \mu_y)]$$

En particular, $\text{Cov}(x, x) = \text{Var}(x) \geq 0$.

Varianza y covarianza

Notar que $\text{Cov}(x, y) = 0$ no implica necesariamente que $x \perp y$ ya que la covarianza solo puede captar relaciones lineales entre las variables.

Cuando se tiene una v.a. $x = (x_1, \dots, x_D) \sim p(x)$ en $\mathbb{R}^D$, es posible construir su **matriz de covarianzas**, $\text{Cov}(x) \in \mathcal{M}_{D,D}(\mathbb{R})$:

$$\text{Cov}(x)_{ij} := \text{Cov}(x_i, x_j)$$

En particular, la diagonal de esta matriz contiene las varianzas de cada componente de x .

Notando que $\text{Cov}(x_i, x_j) = \text{Cov}(x_j, x_i)$, se tiene que la matriz de covarianzas siempre es simétrica.

Redes neuronales

Una **red neuronal** es una función *adaptable* $f : \mathbb{R}^D \rightarrow \mathbb{R}^C$ que se puede **entrenar** para replicar el comportamiento de otra función $f_{\text{data}} : \mathbb{R}^D \rightarrow \mathbb{R}^C$ desconocida.

Para esto, se utiliza un **conjunto de entrenamiento**

$$\mathcal{D} = \{(x^1, y^1), \dots, (x^N, y^N)\} \subset \mathbb{R}^D \times \mathbb{R}^C,$$

donde cada instancia $(x^n, y^n) \in \mathcal{D}$ es de la forma $y^n = f_{\text{data}}(x^n)$.

De este modo, cuando la red neuronal f está entrenada,

$$f(x^n) \approx f_{\text{data}}(x^n) \quad \text{para todo } n \in \{1, \dots, N\}.$$

Una red neuronal está formada por la composición de $K \in \mathbb{N}$ funciones individuales, $f_k : \mathbb{R}^{D_{k-1}} \rightarrow \mathbb{R}^{D_k}$ (con $D_0 = D$ y $D_K = C$):

$$f(x) = f_K(f_{K-1}(\dots(f_1(x))\dots))$$

Cada **capa** f_k tiene asociado un conjunto de **parámetros** $\theta_k \in \mathbb{R}^{P_k}$ que van cambiando durante el entrenamiento.

Se pueden concatenar los K parámetros en un único vector $\theta \in \mathbb{R}^P$, con $P = \sum_{k=1}^K P_k$, lo que motiva a usar la notación f_θ .

Las redes neuronales serán, por lo general, usadas para ajustar los parámetros de una distribución de probabilidad.

Para entrenar una red neuronal es necesario elegir una **función de pérdida** $L : \mathbb{R}^C \times \mathbb{R}^C \rightarrow \mathbb{R}$.

Esta función mide la discrepancia entre el valor real y el valor predicho por la red neuronal para una instancia $(x^n, y^n) \in \mathcal{D}$.

De esta forma, la función de pérdida total sobre el conjunto de entrenamiento $\mathcal{D} = \{(x^1, y^1), \dots, (x^N, y^N)\} \subset \mathbb{R}^D \times \mathbb{R}^C$ es:

$$\mathcal{L}_{\mathcal{D}}(\theta) = \frac{1}{N} \sum_{n=1}^N L(f_{\theta}(x^n), y^n)$$

Para entrenar una red neuronal se deben ajustar sus parámetros de tal forma que minimicen el valor de $\mathcal{L}_{\mathcal{D}}(\theta)$.

Para esto, lo más usual es usar **algoritmos de gradiente**, los cuales realizan iteraciones de la forma

$$\theta \leftarrow \theta - \gamma \nabla_{\theta} \mathcal{L}_{\mathcal{D}}(\theta),$$

donde la constante $\gamma > 0$ se llama **tasa de aprendizaje**.

Todos los optimizadores usados necesitan conocer $\nabla_{\theta} \mathcal{L}_{\mathcal{D}}(\theta)$, lo cual es obtenido mediante **backpropagation**.

Redes fully connected

El tipo de red neuronal más simple es la red **fully connected**, donde cada capa $f_k : \mathbb{R}^{D_{k-1}} \rightarrow \mathbb{R}^{D_k}$ es de la forma

$$f_k(x) = \Phi(A_k x + b_k),$$

con $A_k \in \mathcal{M}_{D_k, D_{k-1}}(\mathbb{R})$ y $b_k \in \mathbb{R}^{D_k}$ los parámetros de f_k .

La función $\Phi : \mathbb{R}^{D_k} \rightarrow \mathbb{R}^{D_k}$ suele ser una misma función que se aplica en cada coordenada del vector de **pre-activación**:

$$\Phi(y) = (\phi(y_1), \dots, \phi(y_{D_k})) ,$$

donde $\phi : \mathbb{R} \rightarrow \mathbb{R}$ es una función no lineal fija llamada **función de activación**.

Redes neuronales con múltiples entradas

Las redes neuronales pueden ser modificadas para que reciban información adicional (p.g. un prompt o una imagen).

Para esto, se puede sustituir cada capa $f_k : \mathbb{R}^{D_{k-1}} \rightarrow \mathbb{R}^{D_k}$ por otra capa $f_k : \mathbb{R}^{D_{k-1}} \times \mathbb{R}^J \rightarrow \mathbb{R}^{D_k}$ que sea capaz de procesar un contexto adicional $c \in \mathbb{R}^J$.

Una forma simple de hacer esto en una red FC es la siguiente:

$$f_k(x, c) = \Phi(A_k x + B_k c + d_k),$$

donde $A_k \in \mathcal{M}_{D_k, D_{k-1}}(\mathbb{R})$, $B_k \in \mathcal{M}_{D_k, J}(\mathbb{R})$ y $d_k \in \mathbb{R}^{D_k}$ son los parámetros de la nueva capa f_k .

Clasificación con redes neuronales

Si $\mathcal{D} = \{(x^1, y^1), \dots, (x^N, y^N)\}$ es un dataset compuesto por pares de imágenes y etiquetas de clase, se puede ajustar un modelo probabilístico para predecir la clase $y \in \{M_1, \dots, M_C\}$ a la que pertenece una imagen $x \in \mathbb{R}^D$ dada:

$$p_{\theta}(y|x) \sim \text{Categórica}(r_{\theta}(x)),$$

con $r_{\theta} : \mathbb{R}^D \rightarrow \Delta^C$ una red neuronal que mapea cada imagen $x \in \mathbb{R}^D$ a un vector de probabilidades $r_{\theta}(x) \in \Delta^C$ sobre las clases.

Clasificación con redes neuronales

La salida de la red neuronal $r_\theta : \mathbb{R}^D \rightarrow \Delta^C$ debe ser un vector de probabilidades.

Para esto, se suele usar la función de activación softmax : $\mathbb{R}^C \rightarrow \Delta^C$ en la última capa:

$$\text{softmax}(s) := \left(\frac{e^{s_1}}{\sum_{c=1}^C e^{s_c}}, \dots, \frac{e^{s_C}}{\sum_{c=1}^C e^{s_c}} \right)$$

Como función de pérdida se suele usar la **entropía cruzada**, la cual será revisada en más detalle al estudiar redes bayesianas.

En la próxima clase.

- Introducción a las redes bayesianas.
- Modelos generativos modernos como redes bayesianas.

Modelos Generativos Profundos

Clase 2: Repaso de conceptos previos