

Modelos Generativos Profundos

Clase 3: Redes bayesianas (parte I)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Introducción a las redes bayesianas

Modelos generativos modernos


Introducción a las redes bayesianas

- Toda la información acerca de cómo se relacionan las distintas variables aleatorias dentro de un modelo probabilístico está contenida en su **distribución conjunta** $p(x_1, \dots, x_N)$.
- Muchas veces los modelos suelen incluir **hipótesis de independencia** entre ellas para hacer más simple el modelo.
- Esto regulariza el modelo y permite disminuir la cantidad de parámetros necesarios para definir la distribución conjunta.

Ejemplo inicial

Se tienen 4 variables aleatorias binarias:

- **Variable aleatoria** x_1 : el estudiante estudia para el examen.
- **Variable aleatoria** x_2 : el estudiante responde bien las preguntas teóricas.
- **Variable aleatoria** x_3 : el estudiante responde bien las preguntas prácticas.
- **Variable aleatoria** x_4 : el estudiante aprueba el curso.



Se considera $x_i \sim \text{Bernoulli}(r_i)$ para $i \in \{1, 2, 3, 4\}$, y se asocia la respuesta “sí” al valor 1 y la respuesta “no” al valor 0.

$$p(x_1, x_2, x_3, x_4) = p(x_1)p(x_2|x_1)p(x_3|x_1)p(x_4|x_2, x_3)$$

Ejemplo inicial

- Probabilidad de que el estudiante responda bien las preguntas teóricas.
- Probabilidad de que el estudiante haya estudiado si no respondió bien las preguntas teóricas.
- Probabilidad de que responda bien tanto las preguntas teóricas como las preguntas prácticas.
- Probabilidad de que responda bien las preguntas prácticas si respondió bien las preguntas teóricas.

$p(x_1 = 0)$	$p(x_1 = 1)$
0.10	0.90

x_1	$p(x_2 = 0 x_1)$	$p(x_2 = 1 x_1)$
0	0.80	0.20
1	0.25	0.75

x_1	$p(x_3 = 0 x_1)$	$p(x_3 = 1 x_1)$
0	0.70	0.30
1	0.20	0.80

x_2	x_3	$p(x_4 = 0 x_2, x_3)$	$p(x_4 = 1 x_2, x_3)$
0	0	0.95	0.05
1	0	0.35	0.65
0	1	0.40	0.60
1	1	0.01	0.99

Formulación

Se requieren los siguientes conceptos de teoría de grafos:

- **Grafo dirigido:** estructura compuesta por un conjunto de nodos V y por un conjunto de arcos $E \subset V \times V$.
- **Arco dirigido:** se usa $(u, v) \in E$ para indicar que el grafo posee un arco dirigido desde el nodo $u \in V$ hacia el nodo $v \in V$.
- **Camino dirigido:** secuencia de nodos que sigue el **orden topológico** del grafo.
- **Grafo dirigido acíclico (DAG):** grafo dirigido donde no existen caminos dirigidos que empiecen y terminen en un mismo nodo.
- **Nodos padres:** para cada nodo $v \in V$, el conjunto de sus nodos padres es $\text{Pa}(v) := \{u \in V : (u, v) \in E\}$.

Formulación

La idea general de una **red bayesiana** es poder representar una distribución conjunta $p(x_1, \dots, x_N)$ como un DAG (V, E) .

- Aquí, $V = \{x_1, \dots, x_N\}$, mientras que $(x_i, x_j) \in E$ indica que la variable x_i influye directamente sobre la variable x_j .
- **Propiedad de Markov:** cada nodo es independiente de sus ancestros, es decir: $p(x_n | x_1, \dots, x_{n-1}) = p(x_n | \text{Pa}(x_n))$.
- En consecuencia, la red bayesiana asociada a un DAG propone

$$p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | \text{Pa}(x_n))$$

- Para la generación se utiliza **ancestral sampling**.

Ejemplos

- **Mixtura:** combina N distribuciones independientes, $p_1(x), \dots, p_N(x)$, de acuerdo a una variable latente $p(z) \sim \text{Cat}(\{1, \dots, N\})$, que elige al azar una de las distribuciones para generar la muestra visible x .

$$p(z, x) = p(z) \sum_{n=1}^N \delta_n(z) p_n(x) \quad \text{donde} \quad \delta_n(z) := \begin{cases} 1 & \text{si } z = n \\ 0 & \text{si no} \end{cases}$$

- **Naïve Bayes:** clasificador que asume que $x_i \perp x_j | y$, para todo $i, j \in \{1, \dots, D\}$.

$$p(x, y) = p(y) \prod_{d=1}^D p(x_d | y)$$

Para clasificar una nueva muestra $x \in \mathbb{R}^D$, este modelo calcula $p(y|x)$ mediante la regla de Bayes y elige la clase más probable.

Ejemplos

- **Cadena de Markov:** modela secuencias de variables (noción temporal). Asumen que el futuro es independiente del pasado dado el presente: $p(x_{t+1}|x_1, \dots, x_t) = p(x_{t+1}|x_t)$.

$$p(x) = p(x_1) \prod_{t=1}^{T-1} p(x_{t+1}|x_t)$$

- **Modelo de Markov oculto (HMM):** modela secuencias asumiendo la existencia de una cadena de Markov latente, $z = (z_1, \dots, z_T)$, la cual va generando las observaciones visibles $x = (x_1, \dots, x_T)$.

$$p(z, x) = p(z_1) \prod_{t=1}^{T-1} p(z_{t+1}|z_t) \prod_{t=1}^T p(x_t|z_t)$$

Modelos generativos modernos

Formulación naïve

- El objetivo es aproximar una **distribución desconocida** $p_{\text{data}}(x)$, de la cual solo se conocen algunas muestras, $\mathcal{D} = \{x^1, \dots, x^K\}$.
- Una forma directa es usar la **distribución empírica**, cuya función de masa es

$$p_{\mathcal{D}}(x) = \frac{1}{K} \sum_{k=1}^K \delta_{x^k}(x), \quad \text{donde} \quad \delta_{x^k}(x) := \begin{cases} 1 & \text{si } x = x^k \\ 0 & \text{si no} \end{cases}$$

- **Kernel density estimation** utiliza un kernel de densidad (función de densidad con $\mathbb{E}_{x \sim \mathcal{K}} [x] = 0$), $\mathcal{K} : \mathbb{R} \rightarrow \mathbb{R}_+$, para definir

$$p_{\text{KDE}}(x) = \frac{1}{K} \sum_{k=1}^K \mathcal{K}(x - x^k)$$

Modelos generativos modernos

- **Modelo autorregresivo (ARM):** modela la generación de secuencias temporales.

$$p(x) = p(x_1) \prod_{n=1}^{T-1} p(x_{t+1}|x_1, \dots, x_t)$$

- **Autoencoder variacional (VAE):** modelo de variable latente $p(x, z) = p(z)p(x|z)$ que también entrena otro modelo $q(z|x)$ para aproximar $p(z|x)$.
- **Red generativa adversaria (GAN):** modelo de variable latente $p(x, z) = p(z)p(x|z)$ que también entrena un clasificador $q(y|x)$ para reconocer imágenes falsas (usado para el entrenamiento).

Modelos generativos modernos

- **Modelo de difusión (DM):** una cadena de Markov (fija) inyecta ruido a muestras de $p_{\text{data}}(x_0)$.

$$q(x_0, x_1, \dots, x_T) = p_{\text{data}}(x_0) \prod_{t=1}^T q(x_t | x_{t-1}), \quad q(x_T) \approx \mathcal{N}(0, I_D)$$

Otra cadena de Markov (red neuronal) aprende a deshacer el proceso de inyección de ruido.

$$p(x_0, x_1, \dots, x_T) = p(x_T) \prod_{t=1}^T p(x_{t-1} | x_t), \quad p(x_T) \sim \mathcal{N}(0, I_D)$$

Modelos generativos modernos

- **Flujo normalizante (NF):** modelo de variable latente $p(x, z) = p(z)p(x|z)$ que transforma $p(z) \sim \mathcal{N}(0, I_D)$ en $x = f(z)$ a través de una serie de transformaciones aprendidas

$$\begin{aligned} f(z) &= (f_N \circ \dots \circ f_1)(z) \\ &= f_N(f_{N-1}(\dots f_1(z) \dots)) \end{aligned}$$

Notar que $p(x|z) \sim \delta_{f(z)}(x)$, por lo que el valor de z determina x desde un comienzo.

- **Flow matching (FM):** formulación a tiempo continuo de los NFs. Se puede considerar el SOTA actual en generación de imágenes.

Modelos generativos condicionales

- En muchos casos se cuenta con información adicional que se quiere que influya en el proceso de generación.
- En lugar de modelar $p(x)$, se busca aprender una **distribución condicional** $p(x|y)$, donde y representa una variable observada fija, cuyo valor usualmente está definido por el usuario.
- Algunos ejemplos son traducción de texto, generación de imágenes y video a partir de descripciones, modificación de imágenes, superresolución, chatbots y síntesis de voz.
- Cualquier modelo incondicional $p(x_1, \dots, x_N) = \prod_{n=1}^N p(x_n | \text{Pa}(x_n))$ se puede transformar en un modelo condicional mediante

$$p(x_1, \dots, x_N | y) = \prod_{n=1}^N p(x_n | \text{Pa}(x_n), y)$$

En la próxima clase.

- Modelos de variable latente.
- Estimación de parámetros.

Modelos Generativos Profundos

Clase 3: Redes bayesianas (parte I)