

Modelos Generativos Profundos

Clase 14: Autoencoders variacionales (parte I)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Autoencoders clásicos

Introducción a los VAEs

Autoencoders clásicos

Autoencoder clásico

Un **autoencoder (AE)** es una red neuronal utilizada para aprender representaciones *eficientes* de una distribución de datos.

Un AE está compuesto por dos partes:

- **Encoder:** red neuronal $E_\phi : \mathbb{R}^D \mapsto \mathbb{R}^L$ que mapea los datos a un espacio de menor dimensión ($L \ll D$).
- **Decoder:** red neuronal $D_\theta : \mathbb{R}^L \mapsto \mathbb{R}^D$ que reconstruye los datos originales a partir de la representación comprimida.

Por lo que un AE es una función $f_{\phi,\theta} : \mathbb{R}^D \rightarrow \mathbb{R}^D$ que compone ambas redes neuronales:

$$\begin{aligned} f_{\phi,\theta}(x) &= (D_\theta \circ E_\phi)(x) \\ &= D_\theta(E_\phi(x)) \end{aligned}$$

Para el entrenamiento, es usual minimizar el **error cuadrático medio (MSE) de reconstrucción** sobre un conjunto de datos de entrenamiento, $\mathcal{D} = \{x^1, \dots, x^N\} \subset \mathbb{R}^D$:

$$\min_{\phi, \theta} \mathcal{L}_{\text{MSE}}(\phi, \theta), \quad \text{donde} \quad \mathcal{L}_{\text{MSE}}(\phi, \theta) = \frac{1}{N} \sum_{n=1}^N \|x^n - D_{\theta}(E_{\phi}(x^n))\|^2$$

Un AE entrenado se puede utilizar para diversas tareas:

- Reducción de dimensionalidad.
- Detección de anomalías.
- ¿Generación de datos?

Tipos de autoencoders

Existen varias variantes de la formulación anterior, por ejemplo:

- **Sparse autoencoder (SAE):** considera $L > D$ e incentiva una representación sparse.
- **Denoising autoencoder (DAE):** corrompe los datos con ruido y entrena al AE para que reconstruya los datos originales.
- **Contractive autoencoder (CAE):** regulariza la función objetivo para que el encoder sea robusto a pequeñas perturbaciones en los datos de entrada.
- **Variational autoencoder (VAE):** modela probabilísticamente el espacio latente y el proceso de generación de datos.

Este curso está enfocado en los VAEs ya que su formulación probabilística los transforma en **modelos generativos**.

Introducción a los VAEs

Formulación de un VAE

Dada una red bayesiana de variable latente, $p_\theta(x, z) = p_\theta(z)p_\theta(x|z)$, sabemos que la marginal $p_\theta(x) = \int_{\mathbb{R}^L} p_\theta(x, z) dz$ es intratable en la práctica, por lo que no es posible entrenar el modelo directamente mediante máxima verosimilitud.

Las GANs abordan este problema utilizando un discriminador auxiliar (**verosimilitud implícita**), mientras que los VAEs lo hacen mediante inferencia variacional (**verosimilitud aproximada**).

Para esto, notar que $p_\theta(x)$ se puede escribir como

$$p_\theta(x, z) = p_\theta(z|x)p_\theta(x) \implies p_\theta(x) = \frac{p_\theta(x, z)}{p_\theta(z|x)}$$

Por lo tanto, se puede usar una segunda red neuronal para aprender una distribución $q_\phi(z|x)$ que estime la posterior $p_\theta(z|x)$.

Evidence lower bound (ELBO)

Un VAE entrena la red neuronal del **decoder** $p_\theta(x|z)$ y del **encoder** $q_\phi(z|x)$ usando un conjunto de entrenamiento $\mathcal{D} \subset \mathbb{R}^D$:

$$\max_{\theta, \phi} \frac{1}{|\mathcal{D}|} \sum_{x \in \mathcal{D}} \text{ELBO}(x),$$

donde $\text{ELBO}(x) \in \mathbb{R}$ es la siguiente función objetivo *natural*:

$$\text{ELBO}(x) := \log p_\theta(x) - D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x))$$

Recordar que la divergencia de Kullback-Leibler entre dos distribuciones p y q es la cantidad

$$D_{\text{KL}}(p \| q) := \mathbb{E}_{p(z)} \left[\log \left(\frac{p(z)}{q(z)} \right) \right] = \int_{\mathbb{R}^L} \log \left(\frac{p(z)}{q(z)} \right) p(z) \, dz$$

Además, dado que esta divergencia es no negativa, se tiene que $\text{ELBO}(x) \leq \log p_\theta(x)$, lo que justifica el nombre *ELBO*.

Si bien la log-verosimilitud $\log p_\theta(x)$ no es tratable, la ELBO se puede reordenar para obtener una forma tratable, lo que permite entrenar las redes neuronales eficientemente:

$$\text{ELBO}(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{término de reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z))}_{\text{prior matching}}$$

En la próxima clase:

- Reformulación de la ELBO.
- Implementación continua y discreta.
- Interpolación en el espacio latente.

Modelos Generativos Profundos

Clase 14: Autoencoders variacionales (parte I)