

Modelos Generativos Profundos

Clase 15: Autoencoders variacionales (parte II)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Recuerdo clase anterior

ELBO en un VAE

Interpolación y VAE condicional

Recuerdo clase anterior

Un **VAE** es un modelo de variable latente $p_\theta(x, z) = p_\theta(z)p_\theta(x|z)$, el cual utiliza un segundo modelo auxiliar, $q_\phi(z|x)$ para aproximar la posterior intractable $p_\theta(z|x)$.

Un VAE se entrena maximizando la **ELBO** media sobre un conjunto de datos de entrenamiento, $\mathcal{D} = \{x^1, \dots, x^N\} \subset \mathbb{R}^D$:

$$\max_{\theta, \phi} \frac{1}{N} \sum_{n=1}^N \text{ELBO}(x^n),$$

donde la *Evidence Lower BOund* se define como

$$\text{ELBO}(x) := \log p_\theta(x) - D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z|x))$$

Notar que $\text{ELBO}(x) \leq \log p_\theta(x)$, lo que justifica su nombre.

Forma equivalente para la ELBO

La ELBO es una función objetivo natural. Sin embargo, su forma original no es tratable debido a los términos $p_\theta(x)$ y $p_\theta(z|x)$.

Se pueden reordenar los términos de la ELBO para obtener la siguiente forma equivalente:

$$\text{ELBO}(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{término de reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p_\theta(z))}_{\text{prior matching}}$$

En esta forma alternativa, la ELBO se puede calcular de forma eficiente si se eligen distribuciones adecuada.

ELBO en un VAE

La reformulación de la ELBO sugiere realizar la siguiente elección de distribuciones para hacer esta cantidad tratable:

- **Prior latente:** $p_{\theta}(z) \sim \mathcal{N}(0, I_L)$.
- **Encoder:** $q_{\phi}(z|x) \sim \mathcal{N}(\mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x)))$, donde $\mu_{\phi} : \mathbb{R}^D \rightarrow \mathbb{R}^L$ y $\sigma_{\phi} : \mathbb{R}^D \rightarrow \mathbb{R}_{++}^L$ son redes neuronales.
- **Decoder:** dependerá de la naturaleza de los datos.

Prior matching

Dadas dos distribuciones gaussianas en $\mathbb{R}^L$, su divergencia de Kullback-Leibler tiene forma cerrada:

$$\begin{aligned} D_{\text{KL}}(\mathcal{N}(\mu_1, \Sigma_1) \parallel \mathcal{N}(\mu_2, \Sigma_2)) \\ = \frac{1}{2} \left[(\mu_1 - \mu_2)^\top \Sigma_2^{-1} (\mu_1 - \mu_2) + \text{traza}(\Sigma_1 \Sigma_2^{-1}) - L - \log |\det(\Sigma_1 \Sigma_2^{-1})| \right] \end{aligned}$$

Dado que $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$ y $p_\theta(z) \sim \mathcal{N}(0, \mathbf{I}_L)$, se tiene una forma cerrada para el término de **prior matching**:

$$\begin{aligned} D_{\text{KL}}(q_\phi(z|x) \parallel p_\theta(z)) \\ = \frac{1}{2} (\|\mu_\phi(x)\|^2 + \|\sigma_\phi(x)\|^2) - \sum_{l=1}^L \log \sigma_\phi(x)_l + \text{constante} \end{aligned}$$

Término de reconstrucción | Reparametrización

Dado que $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$, esta v.a. se puede reparametrizar usando el cambio de variable

$$z = \mu_\phi(x) + \sigma_\phi \odot \epsilon, \quad \text{con } \epsilon \sim \mathcal{N}(0, \mathbf{I}_L)$$

Luego, el **término de reconstrucción** se puede escribir como

$$\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] = \mathbb{E}_{\epsilon \sim \mathcal{N}(0, \mathbf{I}_L)} [\log p_\theta(x|\mu_\phi(x) + \sigma_\phi \odot \epsilon)]$$

Esta esperanza se puede aproximar usando Monte Carlo:

$$\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] \approx \frac{1}{K} \sum_{k=1}^K \log p_\theta(x|\tilde{z}^k),$$

donde $\tilde{z}^k = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon_k$, con $\epsilon_k \sim \mathcal{N}(0, \mathbf{I}_L)$.

Término de reconstrucción | Caso gaussiano

si los datos en $p_{\text{data}}(x)$ son de naturaleza continua, es usual considerar una distribución gaussiana:

$$p_{\theta}(x|z) \sim \mathcal{N}(\mu_{\theta}(z), \sigma_0^2 \mathbf{I}_D),$$

donde $\mu_{\theta} : \mathbb{R}^L \rightarrow \mathbb{R}^D$ es una red neuronal, y $\sigma_0^2 > 0$ es un hiperparámetro. En este caso:

$$p_{\theta}(x|z) = \frac{1}{\sqrt{(2\pi\sigma_0^2)^D}} \exp\left(-\frac{1}{2\sigma_0^2} \|x - \mu_{\theta}(z)\|^2\right)$$

Por lo tanto, la log-densidad del término de reconstrucción se reduce a algo similar a la función objetivo de un AE clásico:

$$\log p_{\theta}(x|z) = -\frac{1}{2\sigma_0^2} \|x - \mu_{\theta}(z)\|^2 + \text{constante}$$

Término de reconstrucción | Caso discreto

Si $p_{\text{data}}(x)$ es una distribución definida sobre imágenes, cada pixel se puede modelar como $p_{\theta}(x_d|z) \sim \text{Bernoulli}(r_d)$, donde $r_{\theta}(z) = (r_1, \dots, r_D) \in [0, 1]^D$ es la salida de una red neuronal $r_{\theta} : \mathbb{R}^L \rightarrow \mathbb{R}^D$.

Con esto, la distribución que se asocia al decoder es

$$\begin{aligned}\log p_{\theta}(x|z) &= \sum_{d=1}^D \log p_{\theta}(x_d|z) \\ &= \sum_{d=1}^D (x_d \cdot \log r_d + (1 - x_d) \cdot \log(1 - r_d))\end{aligned}$$

Interpolación y VAE condicional

Interpolación en el espacio latente

A diferencia de la interpolación en el espacio de las imágenes, $x_t = (1-t)x_0 + tx_1$, la interpolación en latente, $z_t = (1-t)z_0 + tz_1$, suele tener mayor sentido semántico.

Una GAN permite este tipo de interpolación semántica mediante $x_t = \text{generador}(z_t) \in \mathbb{R}^D$. Sin embargo, solo es posible si se conocen las representaciones latentes $z_0, z_1 \in \mathbb{R}^L$.

Un VAE permite obtener estas representaciones latentes de dos muestras $x_0, x_1 \in \mathbb{R}^D$ utilizando el encoder $q_\phi(z|x)$:

$$z_t = (1-t)\text{encoder}(x_0) + t\text{encoder}(x_1)$$

De este modo, $x_t = \text{decoder}(z_t) \in \mathbb{R}^D$ es una muestra interpolada linealmente pero en el espacio latente del VAE.

Al igual que toda red bayesiana, se puede extender la formulación original de un VAE a su **versión condicional**.

Si $y \sim p(y)$ es un factor condicionante (p.g. etiqueta o descripción), entonces un VAE puede aprender una distribución $p_{\theta}(x|y)$:

- **Encoder:** $q_{\phi}(z|x, y)$.
- **Decoder:** $p_{\theta}(x|z, y)$.
- **Prior:** $p(z|y) = p(z)$ (considerando $z \perp y$).

Los parámetros de estas distribuciones son aprendidas por dos redes neuronales que ahora reciben y como entrada adicional.

En la próxima clase:

- Implementación de un VAE para CelebA.

Modelos Generativos Profundos

Clase 15: Autoencoders variacionales (parte II)