

Modelos Generativos Profundos

Clase 16: Autoencoders variacionales (parte III)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Recuerdo previo

Manipulación de atributos

Truco de la reparametrización

Recuerdo previo

Distribuciones del VAE

Un VAE define un **encoder** $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$, un **decoder** $p_\theta(x|z)$ y un **prior** $p(z) \sim \mathcal{N}(0, I_L)$.

$p_\theta(x|z)$ depende de la naturaleza de $p_{\text{data}}(x)$. Si $x \in \mathbb{R}^D$, es una imagen, entonces se suele considerar $p_\theta(x_d|z) \sim \text{Bernoulli}(r_d)$.

Luego, considerando independencia condicional de los pixeles:

$$\begin{aligned}\log p_\theta(x|z) &= \sum_{d=1}^D (x_d \cdot \log r_d + (1 - x_d) \cdot \log(1 - r_d)) \\ &= \text{BCE}(x, r_\theta(z))\end{aligned}$$

Aquí, $r_\theta(z) = (r_1, \dots, r_D) \in [0, 1]^D$ es la salida de una red neuronal con activación sigmoideal.

Para el entrenamiento del encoder y del decoder se maximiza la **ELBO** esperada sobre un conjunto de datos de entrenamiento:

$$\text{ELBO}(x) = \mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)] - D_{\text{KL}}(q_{\phi}(z|x) \| p(z))$$

Desarrollando cada término, se obtiene:


$$\begin{aligned}\mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x|z)] &= \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I_L)} [\log p_{\theta}(x | \mu_{\phi}(x) + \sigma_{\phi} \odot \epsilon)] \\ D_{\text{KL}}(q_{\phi}(z|x) \| p_{\theta}(z)) &= \frac{1}{2} (\|\mu_{\phi}(x)\|^2 + \|\sigma_{\phi}(x)\|^2) - \sum_{l=1}^L \log \sigma_{\phi}(x)_l + \text{cte.}\end{aligned}$$

Para la generación, se realiza **ancestral sampling**, generando desde $z \sim p(z)$ y luego desde $x \sim p_{\theta}(x|z)$.

Manipulación de atributos

Idea general

La continuidad del espacio latente permite modificar la intensidad de algún atributo de una muestra:



Si $\mathcal{X}^+ \subset \mathbb{R}^D$ es un conjunto de muestras que poseen el atributo que se busca modificar y $\mathcal{X}^- \subset \mathbb{R}^D$ un conjunto de muestras que no lo poseen, entonces se pueden considerar los **centroides**

$$z^+ = \frac{1}{|\mathcal{X}^+|} \sum_{x \in \mathcal{X}^+} \text{encoder}(x), \quad z^- = \frac{1}{|\mathcal{X}^-|} \sum_{x \in \mathcal{X}^-} \text{encoder}(x).$$

$z_{\text{attr}} = z^+ - z^- \in \mathbb{R}^L$ es una **dirección latente** asociada al atributo. Luego, para una muestra $x \in \mathbb{R}^D$ y una intensidad $\lambda \in \mathbb{R}$,

$$\tilde{x} = \text{decoder}(\text{encoder}(x) + \lambda z_{\text{attr}}) \in \mathbb{R}^D$$

corresponde a la muestra original $x \in \mathbb{R}^D$ con el atributo amplificado ($\lambda > 0$) o disminuido ($\lambda < 0$).

Truco de la reparametrización

Intercambio gradiente-esperanza

Si $p(x)$ no dependa de θ (e.g. $p_{\text{data}}(x)$), entonces se puede realizar el intercambio $\nabla_{\theta} \mathbb{E}_{p(x)}[f_{\theta}(x)] = \mathbb{E}_{p(x)}[\nabla_{\theta} f_{\theta}(x)]$.

Esto permite aproximar $\nabla_{\theta} \mathbb{E}_{p(x)}[f_{\theta}(x)]$ a través de Monte Carlo:

$$\nabla_{\theta} \mathbb{E}_{p(x)}[f_{\theta}(x)] \approx \frac{1}{K} \sum_{k=1}^K \nabla_{\theta} f_{\theta}(x^k), \quad x^1, \dots, x^K \sim p(x)$$

Esto permite aproximar los gradientes que se necesitan para entrenar una red neuronal f_{θ} que optimiza $\mathbb{E}_{p(x)}[f_{\theta}(x)]$.

Sin embargo, esto no permite entrenar el encoder $q_{\phi}(z|x)$ de un VAE debido al término de reconstrucción, $\nabla_{\phi} \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)]$.

Reparametrización del encoder

Considerando que $q_\phi(z|x) \sim \mathcal{N}(\mu_\phi(x), \text{diag}(\sigma_\phi^2(x)))$, se puede reparametrizar $q_\phi(z|x)$ usando el **truco de la reparametrización**:

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon,$$

donde $\epsilon \sim \mathcal{N}(0, I_L)$ es una v.a. que no depende de ϕ . Luego:

$$\begin{aligned}\nabla_\phi \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] &= \nabla_\phi \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I_L)} [\log p_\theta(x|\mu_\phi(x) + \sigma_\phi(x) \odot \epsilon)] \\ &= \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I_L)} [\nabla_\phi \log p_\theta(x|\mu_\phi(x) + \sigma_\phi(x) \odot \epsilon)] \\ &\approx \nabla_\phi \log p_\theta(x|\mu_\phi(x) + \sigma_\phi(x) \odot \epsilon)\end{aligned}$$

En la última aproximación, se utilizó Monte Carlo considerando una única muestra $\epsilon \sim \mathcal{N}(0, I_L)$.

Próxima clase

En la próxima clase.

- Variantes del VAE.
- 5º control de lectura.

Modelos Generativos Profundos

Clase 16: Autoencoders variacionales (parte III)