

Modelos Generativos Profundos

Clase 19: Modelos de difusión (parte I)

Fernando Fêtis Riquelme

Otoño, 2025

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Formulación de un DDPM


Entrenamiento de un DDPM

Formulación de un DDPM

Idea general

Un **modelo de difusión (DDPM)** es un modelo generativo formado por dos cadenas de Markov:

- **Proceso de difusión:** transforma datos reales en ruido gaussiano mediante la inyección progresiva de ruido.
- **Proceso de denoising:** aprende a deshacer el proceso de difusión, transformando ruido gaussiano en datos reales.



Proceso forward

Dada una secuencia decreciente $(\alpha_t)_{t=1}^T \subset (0, 1)$, el proceso de difusión (**proceso forward**) está definido como:

$$q(x_{0:T}) = q(x_0) \prod_{t=1}^T q(x_t | x_{t-1}),$$

donde $q(x_0) = p_{\text{data}}(x_0)$ y $q(x_t | x_{t-1}) \sim \mathcal{N}(\sqrt{\alpha_t} x_{t-1}, (1 - \alpha_t) I_D)$.

- La secuencia $(\alpha_t)_{t=1}^T$ debe ser tal que $q(x_T) \approx p_{\text{prior}}(x_T)$, donde $p_{\text{prior}}(x_T) \sim \mathcal{N}(0, I_D)$.
- En la práctica, es suficiente considerar $T \gg 1$ y $\alpha_T \in (0, 1)$ lo suficientemente pequeño.

Proceso backward

El proceso de denoising (**proceso backward**) está definido como:

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1}|x_t),$$

donde $p(x_T) = p_{\text{prior}}(x_T)$ y $p_{\theta}(x_{t-1}|x_t) \sim \mathcal{N}(\mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$.

- La media $\mu_{\theta}(x_t, t) \in \mathbb{R}^D$ y la matriz de covarianzas $\Sigma_{\theta}(x_t, t) \in \mathcal{M}_{D,D}(\mathbb{R})$ son aprendidas por redes neuronales.
- En la práctica, es usual fijar $\Sigma_{\theta}(x_t, t)$ a una cantidad conocida.
- En consecuencia, un modelo de difusión solo debe entrenar una red neuronal $\mu_{\theta} : \mathbb{R}^D \times \{0, \dots, T\} \rightarrow \mathbb{R}^D$.

Propiedades del proceso forward

Es necesario revisar dos propiedades del proceso forward, las cuales se utilizarán al definir la función objetivo (ELBO):

- $q(x_t|x_0) \sim \mathcal{N}(\sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I_D)$, donde

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s \in (0, 1)$$

- $q(x_{t-1}|x_t, x_0) \sim \mathcal{N}(\mu_q(x_0, x_t, t), \sigma_q^2(t)I_D)$, donde

$$\begin{cases} \mu_q(x_0, x_t, t) = \frac{\sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)}{1-\bar{\alpha}_t}x_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}x_t \\ \sigma_q^2(t) = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \end{cases}$$

Entrenamiento de un DDPM

ELBO en un modelo de difusión

Los modelos de difusión son modelos de variable latente, por lo que no se puede computar la verosimilitud de forma eficiente.

- **Variable observada:** $x_0 \in \mathbb{R}^D$.
- **Variables latentes:** $(x_1, \dots, x_T) \subset \mathbb{R}^D$.

Para entrenar estos modelos, se puede extender el concepto de **ELBO** utilizado en VAEs:

$$\text{ELBO}(x_0) := \log p_\theta(x_0) - D_{\text{KL}}(q(x_{1:T}|x_0) \| p_\theta(x_{1:T}|x_0)),$$

donde $x_{1:T} = (x_1, \dots, x_T)$. Por otro lado, notar que, al igual que en un VAE, $\text{ELBO}(x_0) \leq \log p_\theta(x_0)$ ya que $D_{\text{KL}}(\cdot \cdot \cdot) \geq 0$.

Forma tratable para la ELBO

La ELBO de un modelo de difusión admite la siguiente descomposición, donde todas las distribuciones son conocidas:

$$\begin{aligned} \text{ELBO}(x_0) = & \mathbb{E}_{q(x_1|x_0)} [\log p_\theta(x_0|x_1)] \\ & - \sum_{t=2}^T \mathbb{E}_{q(x_t|x_0)} [\text{D}_{\text{KL}}(q(x_{t-1}|x_t, x_0) || p_\theta(x_{t-1}|x_t))] \\ & + \text{constante} \end{aligned}$$

- Todas las distribuciones presentes son gaussianas. En particular, las divergencias de Kullback-Leibler tienen forma cerrada.
- Las esperanzas son estimadas usando Monte Carlo.

Forma tratable para la ELBO

Para $D_{\text{KL}}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t))$, se tiene que:

- $q(x_{t-1}|x_t, x_0) \sim \mathcal{N}(\mu_q(x_0, x_t, t), \sigma_q^2(t) \mathbf{I}_D)$.
- $p_{\theta}(x_{t-1}|x_t) \sim \mathcal{N}(\mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$.

Por lo tanto, resulta conveniente fijar $\Sigma_{\theta}(x_t, t) = \sigma_q^2(t) \mathbf{I}_D$. Luego:

$$D_{\text{KL}}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t)) = \frac{1}{2\sigma_q^2(t)} \|\mu_q(x_0, x_t, t) - \mu_{\theta}(x_t, t)\|^2$$

Por otro lado, dado que $p_{\theta}(x_0|x_1) \sim \mathcal{N}(\mu_{\theta}(x_1, 1), \sigma_q^2(1) \mathbf{I}_D)$:

$$\log p_{\theta}(x_0|x_1) = \frac{-1}{2\sigma_q^2(1)} \|\mu_q(x_0, x_1, 1) - \mu_{\theta}(x_1, 1)\|^2 + \text{constante}$$

Forma tratable para la ELBO

En consecuencia, la ELBO de un modelo de difusión se reduce a una suma ponderada de errores cuadráticos:

$$\text{ELBO}(x_0) = - \sum_{t=1}^T \frac{1}{2\sigma_q^2(t)} \mathbb{E}_{q(x_t|x_0)} [\|\mu_q(x_0, x_t, t) - \mu_\theta(x_t, t)\|^2] + \text{cte.}$$

- Es usual omitir los ponderadores $\frac{1}{2\sigma_q^2(t)}$ para darle a todos los sumandos la misma importancia.
- Además, en vez de calcular toda la suma, se suele entrenar el modelo muestreando un único $t \in \{1, \dots, T\}$ por dato x_0 .

Por lo tanto, un modelo de difusión es entrenado minimizando

$$\mathbb{E}_{p_{\text{data}}(x_0), t \sim \text{Uniforme}(\{1, \dots, T\}), q(x_t|x_0)} [\|\mu_q(x_0, x_t, t) - \mu_\theta(x_t, t)\|^2]$$

En la próxima clase.

- Reparametrizaciones equivalentes.
- Generación condicional y guidance.

Modelos Generativos Profundos

Clase 19: Modelos de difusión (parte I)