

Modelos Generativos Profundos

Clase 22: Modelos de difusión (parte IV)

Fernando Fêtis Riquelme

Otoño, 2026

Facultad de Ciencias Físicas y Matemáticas
Universidad de Chile

Adaptadores para DMs

Adaptadores para DMs

Motivación

- Modelos como Stable Diffusion pueden ser fine-tuned usando pares de entrenamiento (imagen,caption).
- Los DMs modernos son muy grandes, por lo que hacer fine-tuning completo sobre estos modelos es costoso (e incluso prohibitivo) en tiempo, memoria y cómputo.
- Un **adaptador** es un conjunto de parámetros adicionales que se añaden al modelo preentrenado y que se entrenan durante el fine-tuning, mientras que los parámetros originales del modelo permanecen fijos.

Low-Rank Adaptation

- Es usual utilizar **LoRA** con datasets pequeños (≈ 20 imágenes) para adaptar el modelo a conceptos o estilos específicos.
- Recordar que LoRA se aplica sobre **capas lineales** (e.g. proyecciones QKV). También existen variantes (e.g. LoCon) que permiten extender LoRA a las capas convolucionales.
- Esta técnica permite, al igual que en LLMs, reducir significativamente el costo de entrenamiento.
- Además, al igual que en LLMs, se pueden combinar múltiples LoRAs en un mismo modelo para mezclar estilos o conceptos.

Los modelos **text-to-image** están limitados en el control de detalles que tienen sobre la generación, incluso cuando se consideran técnicas de prompting o fine-tuning estándar.

Para ciertas tareas es deseable poder guiar la generación con información adicional, como bocetos, mapas de profundidad, mapas de segmentación, etc.




ControlNet es un adaptador construido sobre el encoder y el bloque intermedio de la U-Net de Stable Diffusion, y permite inyectar información condicional en forma de imagen. En particular, permite obtener un modelo image-and-text-to-image.

La idea es clonar ciertos bloques de la U-Net y usarlos para inyectar la imagen que se desea incluir como condición adicional. Las salidas de estos bloques se suman a las entradas del decoder y del bloque intermedio de la U-Net original.

De este modo, los bloques clonados son fine-tuned para extraer la información relevante de la imagen condicional, mientras que los bloques originales permanecen fijos.

El adaptador se inyecta como lo indica el siguiente diagrama:




Es decir, si $f(x)$ es el bloque neuronal original (frozen) y $\tilde{f}(x)$ es una copia entrenable de $f(x)$, entonces

$$y_c = f(x) + \text{ZeroConv} \left(\tilde{f} \left(x + \text{ZeroConv}(c) \right) \right),$$

con ZeroConv un bloque convolucional con pesos inicializados en 0, y c la condición (imagen) que se quiere inyectar al modelo.

ControlNet



- La imagen condicionante se debe pasar por una CNN reductora simple (Stable Diffusion trabaja en el espacio latente de un VAE).
- Es usual omitir aleatoriamente el prompt durante el entrenamiento para forzar al modelo a aprender a usar la información de la imagen condicionante.

ControlNet

Durante el entrenamiento, la ControlNet suele aprender a utilizar la información de la condición de forma abrupta, no gradual (**sudden convergence phenomenon**).



Test input



training step 100




step 1000



step 2000




step 6100



step 6133




step 8000



step 12000

ControlNet

Es posible combinar varias ControlNets en un mismo modelo. Para esto basta combinar las salidas de las distintas ControlNets en una sola salida que se inyecta en la U-Net original.



Multiple condition (pose&depth)

“boy”

“astronaut”

Textual Inversion

Otra posible tarea que se puede realizar con DMs es la de aprender nuevos conceptos de manera precisa a partir de pocos ejemplos (3-5 imágenes).

Si bien se podría intentar hacer fine-tuning estándar, este enfoque suele provocar **catastrophic forgetting**. Además, no necesariamente se aprende bien el concepto que se busca enseñar.


Input
samples



Guided Diffusion
(Text Loss + Init Image)




Ours



Textual Inversion

Textual Inversion inyecta un concepto ampliando el vocabulario del text-encoder. Así, el nuevo concepto se representa como un nuevo embedding en el espacio latente del text-encoder.



Este nuevo vector de embedding se entrena y los pesos del text-encoder y del modelo de difusión permanecen fijos.

Textual Inversion

La nueva *palabra* aprendida puede ser utilizada directamente en prompts en lenguaje natural como si fuese una palabra real.



DreamBooth

Textual Inversion solo actualiza el embedding del nuevo concepto pero deja fijo el resto del modelo, no permitiéndole ajustar sus parámetros para representar mejor el nuevo concepto.

DreamBooth relaja esto y realiza fine-tuning sobre todo el modelo. Más aún, DreamBooth quita la complejidad de aprender un nuevo vector de embedding y en su lugar utiliza como identificador del concepto un **token poco frecuente** ya existente en el vocabulario del text-encoder.



Esta técnica permite utilizar muy pocas imágenes (3-5) para aprender de forma robusta el nuevo concepto.



Input images



in the Acropolis



swimming



sleeping



in a doghouse



in a bucket



getting a haircut

Próxima clase

En la próxima clase.

- Repaso de EDO.
- Introducción a flow matching.

Modelos Generativos Profundos

Clase 22: Modelos de difusión (parte IV)