

Control de Lectura nº7

Nombre: _____

2 de julio de 2026

Instrucciones: Marque la **única** alternativa correcta en cada pregunta. El control de lectura tiene una duración de 25 minutos y no está permitido el uso de apuntes ni dispositivos electrónicos.

1. La técnica de **classifier guidance** para generación condicional se basa en:
 - (a) Utilizar únicamente el score incondicional $\nabla_{x_t} \log q(x_t)$.
 - (b) Entrenar un modelo de difusión distinto, desde cero, para cada clase.
 - (c) Sumar al score incondicional el gradiente de un clasificador $\nabla_{x_t} \log q(y|x_t)$.
 - (d) Minimizar la distancia euclidiana a una imagen de referencia.
2. A diferencia de classifier guidance, la técnica de **classifier-free guidance**:
 - (a) Requiere entrenar un clasificador robusto al ruido por separado.
 - (b) Usa un único modelo condicional que también aprende el caso incondicional, reemplazando la condición por un token nulo ($\emptyset$) durante el entrenamiento.
 - (c) No permite regular la fuerza con que se aplica la condición.
 - (d) Solo sirve para condiciones de tipo imagen.
3. Al aumentar el **guidance scale** en classifier-free guidance, típicamente:
 - (a) No se produce ningún efecto sobre las muestras.
 - (b) Aumenta la diversidad de las muestras y disminuye la fidelidad a la condición.
 - (c) El modelo deja de depender del prompt.
 - (d) Aumenta la fidelidad/alineación con la condición, usualmente a costa de una menor diversidad.
4. Para condicionar la generación con **texto**, es habitual obtener los embeddings de la descripción mediante:
 - (a) Un modelo preentrenado como CLIP o un encoder de texto tipo BERT/T5.
 - (b) Un histograma de colores de la imagen.
 - (c) El propio autoencoder (VAE) del modelo.
 - (d) Un clasificador de dígitos.
5. Las **modulaciones tipo FiLM** en la U-Net se utilizan típicamente para inyectar:
 - (a) Una secuencia de tokens de texto, uno por cada palabra.
 - (b) El ruido gaussiano inicial.
 - (c) El embedding del tiempo t (y un embedding global de la condición), escalando y desplazando las activaciones de los bloques.
 - (d) Los pesos de una LoRA.
6. La **atención cruzada** (*cross-attention*) en la U-Net se usa principalmente para:

-
- (a) Inyectar una secuencia de embeddings (por ejemplo, de texto) como condición.
 - (b) Reducir la resolución espacial de la imagen.
 - (c) Reemplazar la función de pérdida del modelo.
 - (d) Eliminar todo el ruido en un solo paso.
7. El **Diffusion Transformer (DiT)** se caracteriza por:
- (a) Eliminar por completo el proceso de denoising.
 - (b) Reemplazar la arquitectura U-Net por una basada en Transformers (operando sobre parches/latentes).
 - (c) Entrenarse sin ninguna función de pérdida.
 - (d) Operar únicamente en el espacio de píxeles de alta resolución.
8. **Stable Diffusion** es un modelo de difusión *latente*, lo que significa que:
- (a) No utiliza ninguna red neuronal.
 - (b) Agrega ruido únicamente a la mitad de la imagen.
 - (c) Genera imágenes sin ningún tipo de condición.
 - (d) El proceso de difusión ocurre en el espacio latente de un autoencoder (VAE), no directamente en píxeles.
9. En general, un **adaptador** (como LoRA o ControlNet) se caracteriza por:
- (a) Reentrenar todos los parámetros del modelo base desde cero.
 - (b) Agregar y entrenar un conjunto reducido de parámetros nuevos, manteniendo (en general) congelados los parámetros originales del modelo.
 - (c) Eliminar parámetros del modelo para hacerlo más pequeño.
 - (d) Existir solo durante el entrenamiento y no poder usarse en inferencia.
10. **LoRA** reduce el costo del fine-tuning porque:
- (a) Aprende actualizaciones de bajo rango ($\Delta W = BA$) sobre las capas lineales, entrenando muchos menos parámetros que W .
 - (b) Utiliza imágenes de menor resolución.
 - (c) Elimina las capas de atención del modelo.
 - (d) Entrena únicamente la última capa del modelo.
11. **ControlNet** permite condicionar la generación con una imagen (boceto, mapa de profundidad, etc.). Para ello:
- (a) Reentrena la U-Net completa con la nueva condición.
 - (b) Reemplaza el VAE por un clasificador de imágenes.
 - (c) Clona ciertos bloques del encoder (y el bloque intermedio) de la U-Net, los conecta mediante convoluciones inicializadas en cero (*zero-convolutions*) y mantiene congelado el modelo original.
 - (d) Convierte el modelo de difusión en un clasificador de imágenes.
12. Respecto a **Textual Inversion** y **DreamBooth** para aprender un concepto nuevo a partir de pocas imágenes:
- (a) Ambos reentrenan por completo el text-encoder.
 - (b) Textual Inversion aprende únicamente un nuevo embedding (token) dejando el resto del modelo congelado, mientras que DreamBooth hace fine-tuning del modelo asociando el concepto a un identificador.
 - (c) Textual Inversion modifica todos los pesos del modelo y DreamBooth solo aprende un embedding.
 - (d) Ninguno de los dos permite luego usar el concepto en prompts.