

Modelos Generativos Profundos

Clase 10: Redes generativas adversarias (parte I)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

Revisión Tarea 1

Introducción a las GANs

Revisión Tarea 1

Introducción a las GANs

Una red **generativa adversaria (GAN)** es una red bayesiana de variable latente, $p_\theta(x, z) = p(z)p_\theta(x|z)$ entrenada buscando *engañar* a un clasificador binario $q_\phi(y|x)$, el cual a su vez es entrenado para aprender a diferenciar muestras reales ($y = 0$) de muestras generadas ($y = 1$).

Una GAN considera las siguientes distribuciones:

- **Prior sobre el espacio latente:** $p(z) \sim \mathcal{N}(0, I_L)$.
- **Generador:** $p_\theta(x|z) \sim \delta_{G_\theta(z)}(x)$ (i.e., es determinista: $z \mapsto G_\theta(x)$), donde $G_\theta : \mathbb{R}^L \rightarrow \mathbb{R}^D$ es una red neuronal.
- **Discriminador:** $q_\phi(y|x) \sim \text{Bernoulli}(D_\phi(x))$, donde $D_\phi : \mathbb{R}^D \rightarrow [0, 1]$ es una red neuronal.

Formulación

El problema minimax asociado una GAN es el siguiente:

$$\min_{\theta} \max_{\phi} \mathcal{L}_{\text{GAN}}(\theta, \phi),$$

donde $\mathcal{L}_{\text{GAN}}(\theta, \phi) = \mathbb{E}_{(x,y)} [\log q_{\phi}(y|x)]$ es la log-verosimilitud esperada del discriminador sobre una distribución de datos de entrenamiento.

Además, dado que $q_{\phi}(y|x) \sim \text{Bernoulli}(D_{\phi}(x))$, entonces:

$$q_{\phi}(y|x) = \begin{cases} D_{\phi}(x) & \text{si } y = 1 \\ 1 - D_{\phi}(x) & \text{si } y = 0 \end{cases} = D_{\phi}(x)^y (1 - D_{\phi}(x))^{1-y},$$

por lo que la log-verosimilitud del discriminador es

$$\log q_{\phi}(y|x) = y \log D_{\phi}(x) + (1 - y) \log (1 - D_{\phi}(x))$$

Formulación

Para entrenar una GAN, es necesario contar con imágenes reales ($y = 1$) y con imágenes generadas ($y = 0$). Es decir, una GAN se entrena considerando una distribución conjunta

$$p(x, y) = \frac{1}{2} (p_{\text{data}}(x) \delta_1(y) + p_{\theta}(x) \delta_0(y))$$

Por lo tanto:

$$\begin{aligned}\mathcal{L}_{\text{GAN}}(\theta, \phi) &= \mathbb{E}_{(x,y)} [\log q_{\phi}(y|x)] \\ &= \frac{1}{2} (\mathbb{E}_{p_{\text{data}}(x)} [\log D_{\phi}(x)] + \mathbb{E}_{p_{\theta}(x)} [\log(1 - D_{\phi}(x))]) \\ &= \frac{1}{2} (\mathbb{E}_{p_{\text{data}}(x)} [\log D_{\phi}(x)] + \mathbb{E}_{p(z)} [\log(1 - D_{\phi}(G_{\theta}(z)))])\end{aligned}$$

donde se usó que $p_{\theta}(x|z) \sim \delta_{G_{\theta}(z)}(x)$ para $z \sim p(z)$.

Para efectos de implementación, ambas esperanzas se estiman con aproximaciones de Monte Carlo:

- $\mathbb{E}_{p_{\text{data}}(x)}[\cdots]$ se aproxima usando un conjunto de entrenamiento i.i.d. $\mathcal{D} = \{x_1, \dots, x_N\} \subset \mathbb{R}^D$ provenientes desde $p_{\text{data}}(x)$.
- $\mathbb{E}_{p(z)}[\cdots]$ se aproxima usando muestras i.i.d. $\{z_1, \dots, z_N\} \subset \mathbb{R}^L$ generadas desde $p(z) \sim \mathcal{N}(0, I_L)$.

Generación condicional

Se puede extender la formulación de una GAN para aprender distribuciones condicionales $p_{\text{data}}(x|c)$ mediante pares de entrenamiento de la forma $(x, c) \in \mathbb{R}^D \times \mathcal{C}$, donde $\mathcal{C}$ es el conjunto donde vive el factor condicionante del modelo. Por ejemplo:

- **Condicionamiento con etiquetas:** c puede ser una etiqueta de clase. En este caso, se puede utilizar una matriz de embeddings para representar vectorialmente cada etiqueta.
- **Condicionamiento con texto:** $c \in \mathcal{V}^*$ puede ser una secuencia de tokens. En este caso, se puede utilizar un modelo tipo BERT o CLIP para obtener una representación vectorial.
- **Condicionamiento con imágenes:** si c es una imagen, se puede utilizar un modelo tipo ViT (o tipo VAE, que se estudiará más adelante) para la representación vectorial.

Generación condicional

En cualquiera de los casos, la red bayesiana de una **GAN condicional (CGAN)** es la siguiente:

$$p_{\theta}(x, z|c) = p(z)p_{\theta}(x|c, z)$$

donde se ha asumido que $z \perp c$ ya que se sigue usando el prior gaussiano $p(z|c) \sim \mathcal{N}(0, I_L)$ para el espacio latente.

En este caso, ahora el generador es una red neuronal $G_{\theta} : \mathcal{C} \times \mathbb{R}^L \rightarrow \mathbb{R}^D$, mientras que el discriminador es una red neuronal $D_{\phi} : \mathcal{C} \times \mathbb{R}^D \rightarrow [0, 1]$, ambos entrenados de forma adversativa usando la función de pérdida $\mathcal{L}_{\text{CGAN}}(\theta, \phi)$ definida como

$$\mathbb{E}_{p(c)p_{\text{data}}(x|c)} [\log D_{\phi}(c, x)] + \mathbb{E}_{p(c)p(z)} [\log(1 - D_{\phi}(c, G_{\theta}(c, z)))]$$

En la próxima clase.

- Redes convolucionales y convolución transpuesta.
- Arquitectura U-Net.

Modelos Generativos Profundos

Clase 10: Redes generativas adversarias (parte I)