

Modelos Generativos Profundos

Clase 25: Modelos a tiempo continuo (parte I)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

Repaso de EDO

Ecuación de continuidad

Introducción a flow matching

Repaso de EDO

Problema de Cauchy

Dada una función $f : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$, una **EDO** es una ecuación de la forma $\frac{d}{dt}x(t) = f(x(t), t)$, cuyas soluciones $x : [0, 1] \rightarrow \mathbb{R}^D$ suelen estar determinadas por una condición de valor inicial $x(0) = x_0$, formando lo que se conoce como un **problema de Cauchy**:

$$\begin{cases} \dot{x}_t = f(x_t, t) \\ x_0 = x_0 \end{cases}$$

Bajo ciertas hipótesis razonables, esta EDO tiene solución única. Más aún, las trayectorias que se siguen al comenzar desde distintos puntos iniciales no se cruzan.

Algoritmo de Euler

La notación $dx_t = f(x_t, t) dt$ motiva un método natural para aproximar la solución de una EDO numéricamente.

Si $\Delta t > 0$ es un tamaño de discretización y $\Delta x_t = x_{t+\Delta t} - x_t$, entonces, el **algoritmo de Euler** calcula iterativamente

$$x_{t+\Delta t} = x_t + f(x_t, t) \Delta t, \quad t \in \{0, \Delta t, 2\Delta t, \dots, 1\}$$

Ecuación de continuidad

Interpretando la EDO $\frac{d}{dt}x(t) = f(x, t)$ como una partícula que comienza en $x_0 \in \mathbb{R}^D$ y continúa su trayectoria siguiendo un campo de velocidades $f(x, t)$, es posible plantar otra ecuación diferencial que indique la evolución de la **densidad de masa** en el espacio a medida que va pasando el tiempo.

Esta ecuación diferencial será necesaria para la formulación del paradigma de flow matching.

Derivación de la ecuación de continuidad

Dado un fluido en $\mathbb{R}^D$ inmerso en un campo de velocidades $v : \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$, su densidad de masa $\rho : \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}_+$ depende del tiempo debido a los cambios de densidad local.

Para un instante de tiempo fijo $t \in [0, T]$, la masa total dentro de un volumen $\Omega \subset \mathbb{R}^D$ viene dada por $\int_{\Omega} \rho_t(x) dx$. Luego, por conservación de masa:

$$\frac{\partial}{\partial t} \left(\int_{\Omega} \rho_t(x) dx \right) = - \oint_{\partial\Omega} \rho_t(x) v_t(x) dS = - \int_{\Omega} \operatorname{div}(\rho_t v_t)(x) dx$$

donde en la segunda igualdad se utilizó el **teorema de la divergencia de Gauss**.

Derivación de la ecuación de continuidad

En consecuencia:

$$\int_{\Omega} (\partial_t \rho_t(x) - \operatorname{div}(\rho_t v_t)(x)) \, dx = 0$$

Dado que esto se tiene que cumplir para cualquier volumen $\Omega \subset \mathbb{R}^D$, necesariamente el integrando debe ser nulo, es decir:

$$\partial_t \rho_t(x) = \operatorname{div}(\rho_t v_t)(x)$$

Esta ecuación es conocida como **ecuación de continuidad** (o ecuación de transporte), y codifica la restricción de conservación de masa que debe seguir un fluido a medida que se desplaza a lo largo de un campo de velocidades $v(x, t)$.

Ecuación de continuidad

La ecuación de continuidad será útil en flow matching para codificar la restricción de conservación de la masa de probabilidad $x_t \sim p_t(x)$ a medida que se transforma $x_0 \sim p_0(x_0)$ en $x_1 \sim p_1(x_1) \approx p_{\text{data}}(x_1)$ siguiendo un campo de velocidades aprendido por una red neuronal.


Más adelante, esta ecuación será extendida a su versión estocástica, llamada ecuación de Fokker-Planck, la cual permitirá, entre otras cosas, obtener la ecuación diferencial estocástica asociada al proceso de denoising de un modelo de difusión.

Introducción a flow matching

Motivación

El método de **flow matching** propone transportar una distribución $p_0(x)$ (p.g. gaussiana) a otra distribución $p_1(x)$ que sea similar a $p_{\text{data}}(x)$.

Para esto, plantea el problema de aprender el **campo de velocidades** $\tilde{u}_t : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$ que deben seguir las muestras iniciales $x_0 \sim p_0(x_0)$ para transformarse en muestras $x_1 \sim p_1(x_1)$ de la distribución desconocida $p_{\text{data}}(x)$.



Motivación

Para esto, se puede plantear la EDO asociada a este problema,

$$\begin{cases} \dot{x}_t = \tilde{u}(x_t, t) \\ x_0 \sim p_{\text{prior}}(x_0) \end{cases},$$

donde $\tilde{u} : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$ es un campo de velocidades (desconocido) tal que $x_1 \sim p_1(x_1) = p_{\text{data}}(x_1)$ cuando se comienza desde $x_0 \sim p_0(x_0) = p_{\text{prior}}(x_0)$ y se sigue el campo de velocidades dado por $\tilde{u}$.

Para aprender $\tilde{u}(x_t, t) \in \mathbb{R}^D$, se entrena una red neuronal $u^\theta : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$ usando la función de costo

$$L_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \text{Uniforme}([0, T]), x_t \sim p_t(x_t)} \left[\left\| u_t^\theta(x_t) - \tilde{u}_t(x_t) \right\|^2 \right]$$

En la próxima clase.

- Flow matching (continuación).
- Stable Diffusion 3 y FLUX.
- Uso de GPU en la nube.

Modelos Generativos Profundos

Clase 25: Modelos a tiempo continuo (parte I)