

Modelos Generativos Profundos

Clase 26: Modelos a tiempo continuo (parte II)

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

Clase de hoy

Recuerdo clase anterior

Flow matching

Algunos modelos de flow matching

Uso de GPU en la nube

Recuerdo clase anterior

Ecuación de continuidad

Dado un **fluido** con densidad de masa $\rho : \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}_+$, el cual se transporta siguiendo un campo de velocidades $v : \mathbb{R}^D \times [0, T] \rightarrow \mathbb{R}^D$, la **ley de conservación de masa** puede ser codificada mediante la **ecuación de continuidad**:

$$\partial_t \rho_t(x) = -\operatorname{div}(\rho_t v_t)(x)$$

Esta ecuación se puede entender desde una perspectiva probabilística, donde ρ_t es la densidad de probabilidad de una variable aleatoria $x_t \sim p_t(x_t)$ que evoluciona en el tiempo siguiendo el campo de velocidades v_t .



Idea general de flow matching

Flow matching busca *transportar* muestras de una distribución inicial $p_{\text{prior}}(x)$ (p.g. gaussiana) hacia muestras de una distribución final, $p_{\text{data}}(x)$. Este **transporte** puede ser modelado como aprender un campo de velocidades $\tilde{u}(x, t)$ tal que las soluciones del problema de Cauchy

$$\begin{cases} \dot{x}_t = \tilde{u}(x_t, t) \\ x_0 \sim p_{\text{prior}}(x_0) \end{cases},$$

sean tales que $x_1 \sim p_1(x_1) = p_{\text{data}}(x_1)$ cuando se comienza desde una muestra inicial $x_0 \sim p_0(x_0) = p_{\text{prior}}(x_0)$ y se sigue el campo de velocidades $\tilde{u}$.

Idea general



Flow matching

Función objetivo

Para aprender el campo de velocidades desconocido, $\tilde{u}(x_t, t) \in \mathbb{R}^D$, se entrenará una red neuronal $u^\theta : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$ para que aprenda esta cantidad. La función de costo natural para este problema es

$$L_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \text{Uniforme}([0, T]), x_t \sim p_t(x_t)} \left[\left\| u_t^\theta(x_t) - \tilde{u}_t(x_t) \right\|^2 \right],$$

la cual no es computable ya que no se conoce la distribución $p_t(x_t|x_0)$ ni el campo de velocidades $\tilde{u}_t(x_t)$.

Se trabajará esta expresión para llegar a una expresión equivalente fácil de evaluar para poder entrenar eficientemente la red neuronal u_t^θ .


Teniendo la red entrenada (i.e., con $u_t^\theta(x_t) \approx \tilde{u}_t(x_t)$), es posible generar nuevas muestras comenzando desde $x_0 \sim p_{\text{prior}}(x_0)$ y luego simulando la EDO

$$\begin{cases} \dot{x}_t = u_t^\theta(x_t) \\ x_0 = x_0 \end{cases}$$

hasta llegar a $x_1 \sim p_1(x_1) \approx p_{\text{data}}(x_1)$. Para la simulación, se puede utilizar el algoritmo de Euler:

$$x_{t+\Delta t} = x_t + u_t^\theta(x_t) \Delta t, \quad t \in \{0, \Delta t, 2\Delta t, \dots, 1\}$$

Generación




Simplificación del problema

El campo de velocidades objetivo, $\tilde{u} : \mathbb{R}^D \times [0, 1] \rightarrow \mathbb{R}^D$, y las trayectorias de probabilidad $p_t(x_t)$ son desconocidos. Es posible descomponer el problema de aprender el campo de velocidades $\tilde{u}_t$ por una versión más simple:

- Se fija una muestra $x_1 \sim p_{\text{data}}(x_1)$.
- Para esta muestra fija, se propone el problema de aprender un campo de velocidades condicional $\tilde{u}_t(x_t|x_1)$ que transporte todos los elementos $x_0 \sim p_{\text{prior}}(x_0)$ al punto $x_1 \in \mathbb{R}^D$.
- Este transporte condicional ocurre siguiendo trayectorias de probabilidad condicional $p_t(x_t|x_1)$.

Simplificación del problema



Simplificación del problema

En este nuevo problema, la distribución de llegada es determinista ya que concentra toda su masa en un único punto $x_1 \in \mathbb{R}^D$.

Este simple cambio permite encontrar fácilmente trayectorias de probabilidad condicional $p_t(x_t|x_1)$ (con su respectivo campo de velocidades $\tilde{u}_t(x_t|x_1) \in \mathbb{R}^D$) que cumplan las condiciones de transporte deseadas:

- $p_0(x_0|x_1) \sim p_{\text{prior}}(x_0)$
- $p_0(x_1|x_1) \sim \delta(x_1)$

Trayectorias condicionales gaussianas

Considerando $p_{\text{prior}}(x_0) \sim \mathcal{N}(0, I_D)$, una forma directa de lograr el objetivo es considerar las siguientes trayectorias gaussianas:

$$p_t(x_t|x_1) \sim \mathcal{N}(\alpha_t x_1, \beta_t^2 I_D),$$

donde $(\alpha_t)_{t \in [0,1]} \subset \mathbb{R}$ y $(\beta_t)_{t \in [0,1]} \subset \mathbb{R}_+$ son secuencias creciente y decreciente respectivamente, con $\alpha_0 = \beta_1 = 0$ y $\alpha_1 = \beta_0 = 1$.

Notar que los modelos de difusión tienen las mismas marginales $p_t(x_t|x_1)$ (con el tiempo invertido) cuando se consideran las opciones *más simples*:

$$\alpha_t = t \quad \text{y} \quad \beta_t = 1 - t.$$

Esta suele ser la elección típica, y resulta coincidir con la formulación del paradigma de **rectified flow**.

Trayectorias condicionales gaussianas

Al considerar $p_t(x_t|x_1) \sim \mathcal{N}(\alpha_t x_1, \beta_t^2 I_D)$, las trayectorias condicionales son completamente conocidas:

$$x_t = \alpha_t x_1 + \beta_t x_0 \quad \text{con} \quad x_0 \sim p_{\text{prior}}(x_0)$$

Más aún, es directo obtener el campo de velocidades condicional $\tilde{u}_t(x_t|x_1) \in \mathbb{R}^D$ asociado a estas trayectorias:

$$\begin{aligned}\tilde{u}_t(x_t|x_1) &= \dot{x}_t \\ &= \dot{\alpha}_t x_1 + \dot{\beta}_t x_0 \\ &= \dot{\alpha}_t x_1 + \dot{\beta}_t \left(\frac{x_t - \alpha_t x_1}{\beta_t} \right) \\ &= \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) x_1 + \frac{\dot{\beta}_t}{\beta_t} x_t\end{aligned}$$

Función objetivo tratable

Teniendo la distribución condicional $p_t(x_t|x_1)$ es directo obtener la distribución $p_t(x_t) = \int_{\mathbb{R}}^D p_t(x_t|x_1)p_{\text{data}}(x_1)dx_1$ necesaria en $L_{FM}(\theta)$. Sin embargo, sigue siendo necesario obtener el campo de velocidades incondicional, $\tilde{u}_t(x_t)$.

El campo $\tilde{u}_t(x_t)$ puede ser obtenido a partir del campo $\tilde{u}_t(x_t|x_1)$. Para esto, se usarán las ecuaciones de continuidad.

- Ecuación asociada a $\tilde{u}_t(x_t)$:

$$\partial_t p_t(x_t) = -\text{div}(p_t \tilde{u}_t)(x_t)$$

- Ecuación asociada a $\tilde{u}_t(x_t|x_1)$:

$$\partial_t p_t(x_t|x_1) = -\text{div}(p_t(\cdot|x_1)\tilde{u}_t(\cdot|x_1))(x_t)$$

Función objetivo tratable

Desarrollando la ecuación de continuidad incondicional:

$$\partial_t p_t(x_t) = -\operatorname{div} \left(p_t(\cdot) \int_{\mathbb{R}^D} \tilde{u}_t(\cdot|x_1) p_t(x_1|\cdot) dx_1 \right) (x_t)$$

En consecuencia, se identifica que:

$$\begin{aligned} \tilde{u}_t(x_t) &= \int_{\mathbb{R}^D} \tilde{u}_t(x_t|x_1) p_t(x_1|x_t) dx_1 \\ &= \mathbb{E}_{p_t(x_1|x_t)} [\tilde{u}_t(x_t|x_1)], \end{aligned}$$

por lo que es posible expresar el campo vectorial desconocido, $\tilde{u}_t(x_t)$, en función del campo condicional conocido, $\tilde{u}_t(x_t|x_1)$.

Función objetivo final

Se puede sustituir la expresión anterior en $L_{\text{FM}}(\theta)$ para llegar a una cantidad tratable:

$$\begin{aligned} L_{\text{FM}}(\theta) &= \mathbb{E}_{t, p_t(x_t)} \left[\left\| u_t^\theta(x_t) - \tilde{u}_t(x_t) \right\|^2 \right] \\ &= \mathbb{E}_{t, p_{\text{data}}(x_1), p_t(x_t|x_1)} \left[\left\| u_t^\theta(x_t) - \tilde{u}_t(x_t|x_1) \right\|^2 \right] + \text{cte} \end{aligned}$$

En particular, usando $\tilde{u}_t(x_t|x_1) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) x_1 + \frac{\dot{\beta}_t}{\beta_t} x_t$ asociado a $p_t(x_t|x_1) \sim \mathcal{N}(\alpha_t x_1, \beta_t^2 I_D)$, se llega a la función objetivo usual,

$$\mathbb{E}_{t, p_{\text{data}}(x_1), \epsilon \sim \mathcal{N}(0, I_D)} \left[\left\| u_t^\theta(t x_1 + (1-t)\epsilon) - (x_1 - \epsilon) \right\|^2 \right] + \text{cte},$$

donde se sustituyó $\alpha_t = t$ y $\beta_t = 1 - t$.

Algunos modelos de flow matching

Uso de GPU en la nube

En la próxima clase.

- Conceptos de cálculo estocástico.
- Modelos de difusión a tiempo continuo.

Modelos Generativos Profundos

Clase 26: Modelos a tiempo continuo (parte II)