

# Modelos Generativos Profundos

## Clase 27: Modelos a tiempo continuo (parte III)

---

Fernando Fêtis Riquelme

Primavera, 2025

Facultad de Ciencias Físicas y Matemáticas

Universidad de Chile

Conceptos de cálculo estocástico

DMs a tiempo continuo

# Conceptos de cálculo estocástico

---

# Movimiento browniano

Un movimiento browniano es un proceso estocástico  $(w_t)_{t \in [0,1]}$  con las siguientes propiedades:

- **Inicio determinista:**  $w_0 \sim \delta_0(w_0)$ . Es decir,  $w_0 = 0$ .
- **Incrementos gaussianos:** dados dos instantes de tiempo  $t_1 < t_2$ , entonces  $w_{t_2} - w_{t_1} \sim \mathcal{N}(0, (t_2 - t_1)I_D)$ .
- **Incrementos independientes:** dados los instantes de tiempo  $t_1 < t_2 < t_3 < t_4$ , entonces,  $(w_{t_4} - w_{t_3}) \perp (w_{t_2} - w_{t_1})$ .
- **Trayectorias continuas:** el mapa  $t \in [0, 1] \mapsto x_t \in \mathbb{R}^D$  es continuo.

# Movimiento browniano

La definición de movimiento browniano nos da un método para simularlo.

Si  $\Delta t > 0$  es un tamaño de discretización, entonces  $\mathcal{N}(0, \Delta t I_D)$ , por lo que basta comenzar en  $w_0 = 0$  y luego ir actualizando el proceso generando incrementos aleatorios:

$$w_{t+\Delta t} = w_t + \sqrt{\Delta t} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I_D)$$

Una **ecuación diferencial ordinaria (ODE)** de la forma

$$dx_t = f(x_t, t) dt$$

se puede interpretar como la evolución de una partícula bajo la influencia de un campo de velocidades,  $f(x_t, t)$ . Este tipo de dinámicas se observa, por ejemplo, en flow matching.

Una **ecuación diferencial estocástica (SDE)** permite agregar un término de ruido a la dinámica de evolución, el cual es modelado usando un movimiento browniano:

$$dx_t = f(x_t, t) dt + g(t) dw_t$$

El término  $f(x_t, t)$  se conoce como **drift** y el término  $g(t)$  como **difusión**.

# Algoritmo de Euler-Maruyama

Las soluciones de una SDE  $dx_t = f(x_t, t) dt + g(t) dw_t$  son procesos estocásticos  $(x_t)_{t \geq 0}$ .

De forma similar a las ODEs, estos procesos pueden ser simulados numéricamente. En particular, se puede adaptar el algoritmo de Euler para ODEs al caso estocástico, obteniendo el **algoritmo de Euler-Maruyama**:

$$x_{t+\Delta t} = x_t + f(x_t, t) \Delta t + g(t) \sqrt{\Delta t} \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, I_D)$$

sujetos a alguna condición o distribución inicial,  $x_0 \sim p_0(x_0)$ .

# Ecuación de Fokker-Planck

Como motivación, se puede considerar un movimiento browniano estándar unidimensional ( $D = 1$ ), cuya SDE viene dada por

$$\begin{cases} dx_t = dw_t \\ x_0 = 0 \end{cases}$$

En este caso, para todo  $t > 0$ ,  $p_t(x_t) \sim \mathcal{N}(0, t)$ :

$$p(x, t) = \frac{1}{\sqrt{2\pi t}} \exp\left(-\frac{x^2}{2t}\right),$$

Se puede verificar directamente que este conjunto de densidades marginales cumple la **ecuación del calor**:

$$\partial_t p(x, t) = \frac{1}{2} \partial_{xx}^2 p(x, t), \quad \forall x \in \mathbb{R}^D, t \in [0, 1].$$



# Ecuación de Fokker-Planck

Este resultado puede ser extendido para  $D > 1$ , donde  $\partial_{xx}^2 p(x, t)$  es sustituido por  $\Delta p(x, t) := \sum_{d=1}^D \partial_{dd}^2 p(x, t)$ .

Más aún, es posible extender el resultado anterior a SDEs más generales:

Dada la SDE  $dx_t = f_t(x_t) dt + g_t dw_t$ , entonces,  $x_t \sim p_t(x_t)$  para todo  $t \in [0, 1]$  si y solo si se cumple la **ecuación de Fokker-Planck**

$$\partial_t p_t(x) = -\operatorname{div}(p_t f_t)(x) + \frac{g_t^2}{2} \Delta p_t(x), \quad \forall x \in \mathbb{R}^D, t \in [0, 1]$$

Si  $\pi$  es una función de densidad en  $\mathbb{R}^D$ , la **dinámica de Langevin**

$$dx_t = \frac{1}{2} \nabla_{x_t} \log \pi(x_t) dt + dw_t$$


tiene distribución invariante  $\pi$ . Es decir,  $p_t(x_t) \rightarrow \pi(x_t)$  cuando  $t \rightarrow \infty$ . En particular, el **algoritmo de Langevin sampling** usado en los EBMs, que es solo una discretización de Euler-Maruyama de la dinámica de Langevin para  $\pi = p_\theta$ , converge a  $p_\theta$ .

## DMs a tiempo continuo

---

# Idea general

El objetivo de los **modelos de difusión a tiempo continuo** es definir una SDE como proceso de difusión hacia adelante que transforme los datos en ruido, y luego aprender una SDE hacia atrás que permita recuperar los datos desde el ruido.



## Teorema de Anderson

Dada la SDE

$$\begin{cases} dx_t = f(x_t, t) dt + g(t) dw_t, \\ x_0 \sim p_0(x_0) \end{cases}$$

entonces la siguiente SDE, definida hacia atrás en el tiempo, tiene las mismas distribuciones marginales  $p_t(x_t)$  que el proceso original:

$$\begin{cases} dx_t = [f(x_t, t) - g(t)^2 \nabla_{x_t} \log p_t(x_t)] dt + g(t) d\bar{w}_t, \\ x_T \sim p_T(x_T) \end{cases}$$

En particular, la única cantidad desconocida en la SDE hacia atrás es el score  $\nabla_{x_t} \log p_t(x_t)$ .

Utilizando el resultado anterior, un DM a tiempo continuo utiliza el siguiente par de SDEs forward-backward:

$$\begin{cases} dx_t = f(x_t, t) dt + g(t) dw_t, & x_0 \sim p_{\text{data}}(x_0) \\ dx_t = [f(x_t, t) - g(t)^2 \nabla_{x_t} \log p_t(x_t)] dt + g(t) d\bar{w}_t, & x_T \sim p_{\text{prior}}(x_T), \end{cases}$$

donde los términos  $f(x_t, t)$  y  $g(t)$  son predefinidos de tal forma que  $p_T(x_T) \approx p_{\text{prior}}(x_T)$ , con  $p_{\text{prior}}$  una distribución simple (p.g., gaussiana).

La cantidad desconocida,  $\nabla_{x_t} \log p_t(x_t)$ , es aproximada por una red neuronal entrenada mediante **score matching**.

## DSM en DMs a tiempo continuo

La función objetivo natural para un DM a tiempo continuo es una versión continua de DSM:

$$\mathbb{E}_{t \sim \text{Uniforme}(0, T)} \left[ \lambda(t) \mathbb{E}_{x_t \sim p_t(x_t)} \left[ \|\nabla_{x_t} \log p_t(x_t) - s_\theta(x_t, t)\|_2^2 \right] \right]$$

Donde el objetivo cuadrático puede ser transformado para obtener una forma tratable:

$$\mathbb{E}_{t \sim \text{Uniforme}(0, T)} \left[ \lambda(t) \mathbb{E}_{x_0 \sim p_{\text{data}}(x_0), x_t \sim p_{t|0}(x_t|x_0)} \left[ \|\nabla_{x_t} \log p_{t|0}(x_t|x_0) - s_\theta(x_t, t)\|_2^2 \right] \right]$$

donde  $p_{t|0}(x_t|x_0)$  es la distribución condicional definida por la SDE forward, la cual es conocida en ciertos casos.

## Probability flow ODE

Para una SDE forward  $dx_t = f(x_t, t) dt + g(t) dw_t$ , es posible definir una ODE llamada **probability flow ODE**,

$$dx_t = \left[ f(x_t, t) - \frac{1}{2} g(t)^2 \nabla_{x_t} \log p_t(x_t) \right] dt$$

la cual tiene las mismas distribuciones marginales  $p_t(x_t)$  que la SDE forward. Notar que, al igual que en la SDE backward, la única cantidad desconocida es el score  $\nabla_{x_t} \log p_t(x_t)$ .

Esto permite poder utilizar solvers eficientes de ODEs para la generacion. Además, permite conectar los DMs a tiempo continuo con modelos flow-based a tiempo continuo.



# Modelos Generativos Profundos

## Clase 27: Modelos a tiempo continuo (parte III)